ABALONE AGE

Dự đoán số vòng tuổi bào ngư từ đặc trưng hình thái và khối lượng

Cao Nguyễn Yên Hòa,Lưu Gia Bảo,Trần Nguyễn Đăng Khoa,Hồ Trung Tín,Lâm Hán Đạt

GIỚI THIỆU:

Bối cảnh:

Trong thực tế, việc xác định tuổi bào ngư thường cần cắt vỏ, nhuộm màu và đếm số vòng tăng trưởng dưới kính hiển vi. Quy trình này tốn chi phí, mất thời gian và khó áp dụng trên quy mô lớn.

Dự án của nhóm nghiên cứu khả năng dự đoán trực tiếp biến `Rings` từ các thông số vật lý và khối lượng dễ thu thập hơn. Bài toán được đặt dưới dạng học máy giám sát cho hồi quy và có ý nghĩa thực tiễn trong nuôi trồng thủy sản và giám sát sinh học.

Mục tiêu dự án

Bài toán cốt lõi của dự án là xây dựng một mô hình hồi quy có khả năng dự đoán chính xác số vòng tuổi `Rings` của bào ngư từ các đặc trưng đầu vào như giới tính, kích thước và khối lượng. Từ mục tiêu này, nhóm hướng đến ba ý chính:

- Giảm phụ thuộc vào phương pháp xác định tuổi thủ công bằng quan sát trực tiếp vòng sinh trưởng.
- Tìm ra nhóm mô hình và cách tiền xử lý phù hợp nhất cho dữ liệu Abalone.
- Đạt sai số dự đoán thấp và khả năng tổng quát hóa tốt trên tập dữ liệu chưa thấy.

DỮ LIỆU:

"Dữ liệu: UCI Machine Learning Repository - Abalone Dataset" (4177 mẫu)

Nguồn dữ liệu Abalone Age:

https://archive.ics.uci.edu/dataset/1/abalone

Bảng mô tả biến

Dữ liệu không có giá trị thiếu, có 1 biến phân loại và 7 biến số. Một số biến khối lượng và Rings có skewness và outlier, vì vậy cần so sánh nhiều chiến lược tiền xử lý.

Biến	Kiểu	Mô tả
Sex	Phân loại	Giới tính: M, F, I
Length	Số thực	Chiều dài lớn nhất của vỏ
Diameter	Số thực	Đường kính vuông góc với chiều dài
Height	Số thực	Chiều cao bào ngư
WholeWeight	Số thực	Khối lượng toàn bộ
ShuckedWeight	Số thực	Khối lượng phần thịt
VisceraWeight	Số thực	Khối lượng nội tạng
ShellWeight	Số thực	Khối lượng vỏ sau sấy
Rings	Số nguyên	Số vòng tuổi, biến mục tiêu

Phân tích dữ liệu

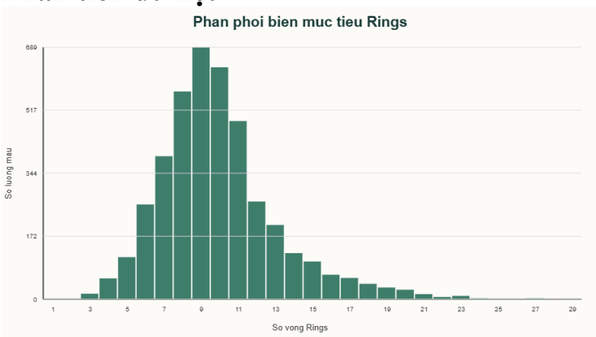

Phân phối của biến mục tiêu Rings.

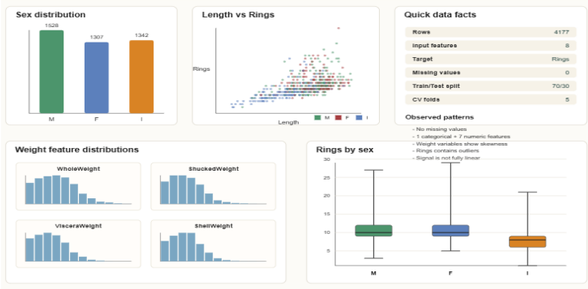

Cụm hình EDA tổng hợp: phân bố, scatter, thống kê nhanh và box-style summary.

QUY TRÌNH THỰC HIỆN:

1. Nạp dữ liệu, chuẩn hóa tên cột, kiểm tra kiểu dữ liệu, duplicate và missing values.
2. Khám phá dữ liệu bằng phân phối biến, tương quan, outlier và quan hệ giữa đặc trưng với Rings.
3. Tạo các pipeline tiền xử lý và ghép với mô hình phù hợp.
4. Huấn luyện, đánh giá bằng 5-fold CV và kiểm thử trên tập hold-out.

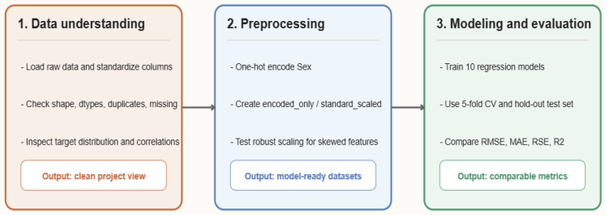

Ba bước chính của quy trình xử lý,tiền xử lý và đánh giá.

TIỀN XỬ LÝ:

Biến thể	Mô tả	Phù hợp
Encode_only	One-hot encoding cho Sex, giữ nguyên các biến số	Mô hình cây
Standard_scaled	One-hot encoding kết hợp chuẩn hóa chuẩn	Mô hình nhạy với scale
Robust_log_scaled	Chuẩn hóa robust và xử lý giảm độ lệch phân phối	Dữ liệu nhiều outlier

Feature engineering

- VolumeApprox
- TotalWeightToShell
- EdibleWeightRatio

MÔ HÌNH HÓA:

Nhóm triển khai đủ 10 mô hình hồi quy theo yêu cầu đề bài, bao gồm cả nhóm tuyến tính, mô hình cây, mô hình kernel và mạng nơ-ron.

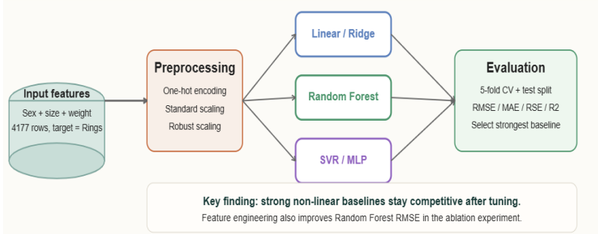

Sơ đồ pipeline từ đặc trưng đầu vào đến đánh giá mô hình.

KẾT QUẢ THỰC NGHIỆM

Random Forest: baseline và tuned

Mô hình	RMSE	MAE	R^2
Baseline Random Forest	2.195	1.543	0.526
Tuned Random Forest	2.172	1.532	0.536

So sánh tiền xử lý

Thiết lập	RMSE	MAE	R^2
linear_encoded_only	2.187	1.583	0.529
linear_standard_scaled	2.187	1.583	0.529
rf_robust_scaled	2.185	1.547	0.530

So sánh feature engineering

Biến thể	RMSE	MAE	R^2
Raw features	2.184	1.546	0.530
Manual feature engineering	2.154	1.527	0.543

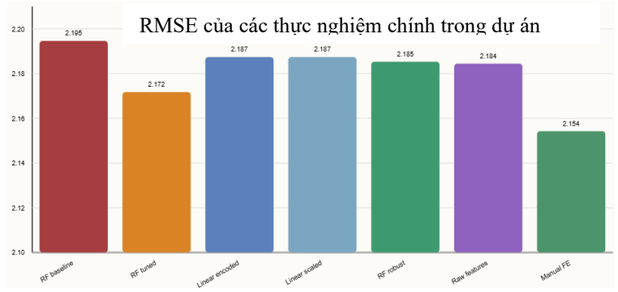

PHÁT HIỆN CHÍNH

Các mô hình phi tuyến phù hợp hơn giả định tuyến tính đơn thuần.

Tiền xử lý theo từng nhóm mô hình giúp so sánh ổn định hơn.

Feature engineering cải thiện kết quả trong thực nghiệm Random Forest.

Baseline mạnh nhất vẫn rất cạnh tranh so với mô hình tuned và ensemble.

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

Kết quả cho thấy một baseline được chuẩn bị tốt vẫn có thể cạnh tranh mạnh, đồng thời các đặc trưng được thiết kế thêm cũng tạo ra cải thiện đo được.

Hướng phát triển

Xuất đầy đủ các hình đánh giá cuối từ notebook.

Bổ sung bảng kết quả cho đủ cả 10 mô hình.

Thêm biểu đồ Actual vs Predicted và residual.

Tunning sâu hơn cho MLPRegressor, SVR và ensemble