BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC SÀI GÒN
KHOA CÔNG NGHỆ THÔNG TIN
--------*--------**

BÁO CÁO
MÔN: CƠ SỞ TRÍ TUỆ NHÂN TẠO

TÊN ĐỀ TÀI: XÁC ĐỊNH SỐ TUỔI CỦA BÀO NGƯ DỰA TRÊN VÒNG SINH TRƯỞNG

Giảng viên hướng dẫn: **TS. Đỗ Như Tài**

Nhóm sinh viên thực hiện:

Cao Nguyễn Yên Hòa	3124410101
Trần Nguyễn Đăng Khoa	3124560042
Lưu Gia Bảo	3124410016
Lâm Hán Đạt	3124410055
Hồ Trung Tín	3124410355

Thành phố Hồ Chí Minh, tháng 03 năm 2026

NHẬN XÉT CỦA GIẢNG VIÊN

.....
.....
.....
.....
.....
.....
.....
.....
.....
.....

MỤC LỤC

CHƯƠNG 1: GIỚI THIỆU ĐỒ ÁN 6
1.1 Bối cảnh và ý nghĩa 6
1.2 Nguồn gốc bộ dữ liệu Abalone 6
1.3 Phát biểu bài toán 7
1.4 Hai hướng tiếp cận xác định tuổi bào ngư 7
1.4.1 Hướng thực nghiệm sinh học 7
1.4.2 Hướng mô hình hoá dữ liệu và học máy 8
1.4.3 So sánh ngắn gọn hai hướng tiếp cận 8
1.5 Mục tiêu và đóng góp chính của đồ án 9
1.5.1. Động lực nghiên cứu 10
1.5.2. Các câu hỏi nghiên cứu trọng tâm 10
CHƯƠNG 2: PHÂN TÍCH BÀI TOÁN VÀ DỮ LIỆU 11
2.1. Mô tả dữ liệu 11
2.2. Những thách thức chính của bài toán 12
2.3. Định hướng phân tích dữ liệu khám phá 13
2.4. Kết quả khám phá dữ liệu từ notebook 01 14
2.4.1 Kích thước và cấu trúc dữ liệu 14
2.4.2 Phân phối biến mục tiêu “Rings” 15
2.4.3 Vai trò của biến “Sex” 15
2.4.4. Ngoại lệ và độ lệch phân phối 17
2.4.5.Tương quan giữa các biến với “Rings” 18
2.5. Giả thuyết rút ra từ phân tích dữ liệu 21
CHƯƠNG 3: PHƯƠNG PHÁP VÀ QUÁ TRÌNH THỰC NGHIỆM 22
3.1. Quy trình triển khai tổng thể 22
3.2. Giai đoạn 1: Khám phá dữ liệu và hình thành giả thuyết 22
3.3. Giai đoạn 2: Tiền xử lý dữ liệu 23
3.3.1. Làm sạch dữ liệu 23
3.3.2. Chia dữ liệu train/test 24
3.3.3. Tạo ba phiên bản dữ liệu 24
3.3.4. Kiểm soát rò rỉ dữ liệu 25
3.3.5. Lưu dữ liệu trung gian 25
3.4. Giai đoạn 3: Huấn luyện 10 mô hình baseline 25
3.4.1. Mười mô hình hồi quy được sử dụng 25
3.4.2. Phương pháp đánh giá 26
3.4.3. Kết quả baseline trên cross-validation 27
3.4.4. Nhận xét từ baseline CV 28
3.5. Giai đoạn 4: Đánh giá khả năng tổng quát hóa trên tập test 28
3.5.1. Kết quả baseline trên tập test 29
3.5.2. Phát hiện quan trọng từ bước đánh giá 30

3.5.3. So sánh chênh lệch giữa CV và test 30
3.5.4. Góc nhìn về chi phí tính toán 31
3.6. Giai đoạn 5: Thử nghiệm bổ sung và tối ưu hóa 31
3.6.1. So sánh “standard_scaled” và “robust_log_scaled” 31
3.6.2. Tuning siêu tham số cho toàn bộ 10 mô hình 32
3.6.3. Kết quả optimized single models 33
3.6.4. So sánh baseline và optimized 34
3.6.5. Ensemble: Weighted Average và Stacking 35
3.7. Tổng kết quá trình thực nghiệm 35
3.8. Tái cấu trúc quy trình Khám phá và Tiền xử lý dữ liệu theo Module 36
3.8.1. Tái cấu trúc quy trình Khám phá dữ liệu (EDA) đa chiều 36
3.8.2. Tiền xử lý dữ liệu (Preprocessing) theo kiến trúc Module 37
3.9. Chiến lược chọn lọc đặc trưng (Feature Selection) đa phương pháp 37
3.9.1. Thiết lập cơ sở tham chiếu (Baseline Evaluation) 37
3.9.2. Triển khai ba phương pháp chọn lọc đặc trưng 38
3.9.3. Đánh giá tổng hợp và Lựa chọn không gian đặc trưng tối ưu 38
3.10. Chiến lược Huấn luyện và Tích hợp mô hình (Modeling & Ensemble Strategy) 39
3.10.1. Nhóm mô hình dựa trên Cây quyết định 39
3.10.2. Đánh giá đối chuẩn và So sánh toàn diện 39
3.10.3. Chiến lược Tích hợp Mô hình (Ensemble Learning) 40
CHƯƠNG 4: KẾT QUẢ VÀ THẢO LUẬN 41
4.1. Thành quả nổi bật nhất của đồ án 41
4.2. Vì sao preprocessing không tạo ra bước nhảy lớn 42
4.3. Vì sao tuning chưa vượt được baseline mạnh nhất 42
4.4. So sánh theo từng nhóm mô hình 43
4.4.1. Nhóm mô hình tuyến tính 43
4.4.2. Nhóm mô hình cây 43
4.4.3. Nhóm mô hình kernel 44
4.4.4. Nhóm mạng nơ-ron 44
4.5. Giá trị học thuật của các kết quả âm 44
4.6. Bổ sung: ý nghĩa của hướng feature engineering trong repo 45
CHƯƠNG 5: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN 46
5.1. Kết luận chung 46
5.2. Những bài học rút ra từ quá trình nghiên cứu 47
5.3. Hướng phát triển tiếp theo 47
5.3.1. Cải tiến phương pháp xác thực chéo và đánh giá độ ổn định 47
5.3.2. Triển khai các thuật toán Boosting hiện đại (SOTA) 47
5.3.3. Khai phá không gian đặc trưng (Feature Engineering & Selection) 48
5.3.4. Ứng dụng Trí tuệ Nhân tạo có thể giải thích (XAI) và Phân tích thặng dư 48

PHÂN CÔNG

1	Cao Nguyễn Yên Hòa	- Lập kế hoạch - Nghiên cứu tài liệu (Paper). - Xây dựng chuỗi 5 notebook nền tảng (Baseline pipeline) bao gồm: Khám phá dữ liệu (01), Tiền xử lý (02), Huấn luyện mô hình (03), Đánh giá (04), và Thử nghiệm bổ sung (05).
2	Trần Nguyễn Đăng Khoa	- Nội dung Report. - Phụ trách luồng phân tích tương quan (EDA correlation). - Tiền xử lý ngoại lệ nâng cao (Preprocessing outlier v2). - Chọn lọc đặc trưng dựa trên mô hình (Feature selection model-based). - Xây dựng module so sánh toàn diện (Model compare v2).
3	Lưu Gia Bảo	- Thiết kế và chỉnh sửa nội dung Report. - Phân tích tổng quan dữ liệu nâng cao (EDA data overview v2). - Phụ trách module mã hóa đặc trưng (Preprocessing encoding). - Chọn lọc đặc trưng thống kê (Feature selection KBest). - Triển khai nhóm mô hình Cây quyết định (Tree models). - Đánh giá chuyên sâu 2 mô hình xuất sắc nhất (Final best 2 models).
4	Lâm Hán Đạt	- Nội dung Slide. - Khám phá tổng quan dữ liệu (EDA data overview). - Xây dựng module tiền xử lý cơ sở (Preprocessing baseline). - Chọn lọc đặc trưng cơ sở (Feature selection baseline). - Triển khai nhóm mô hình Tuyến tính (Linear models). - Xác lập mốc đánh giá cuối cùng (Final baseline).
5	Hồ Trung Tín	- Thiết kế Slide. - Rà soát ngoại lệ (EDA outlier check) và Chuẩn hóa dữ liệu (Scaling). - So sánh và chọn lọc đặc trưng bằng phương pháp Loại bỏ đệ quy (RFE, baseline, compare v2). - Thử nghiệm chiến lược Học tích hợp (Ensemble try 1). - Đóng gói kết quả toàn dự án (Report summary).

CHƯƠNG 1: GIỚI THIỆU ĐỒ ÁN

1.1 Bối cảnh và ý nghĩa

Bào ngư là loài thân mềm chân bụng sống ở biển, có giá trị kinh tế cao trong lĩnh vực thủy sản và chế biến thực phẩm. Ngoài giá trị thương mại, bào ngư còn là đối tượng nghiên cứu quan trọng trong sinh học biển do đặc điểm tăng trưởng phụ thuộc mạnh vào điều kiện môi trường. Vì vậy, việc ước lượng tuổi của bào ngư không chỉ phục vụ mục tiêu khai thác mà còn hỗ trợ theo dõi quần thể và quản lý nguồn lợi một cách bền vững.

Trong thực tế, phương pháp xác định tuổi đáng tin cậy nhất là đếm số vòng sinh trưởng trên vỏ. Tuy nhiên, đây là quy trình thủ công, tốn công, đòi hỏi thao tác cắt, mài, nhuộm và quan sát dưới kính hiển vi. Khi số lượng mẫu lớn, phương pháp này trở nên kém hiệu quả về mặt chi phí và thời gian. Từ đó, bài toán dự đoán tuổi bào ngư từ các đặc trưng vật lý trở thành một hướng tiếp cận phù hợp để ứng dụng học máy vào thực tế.

1.2 Nguồn gốc bộ dữ liệu Abalone

Bộ dữ liệu được sử dụng trong đồ án là **Abalone** từ **UCI Machine Learning Repository**. UCI mô tả đây là bộ dữ liệu dùng để dự đoán tuổi của bào ngư từ các phép đo vật lý, với:

- “4177” mẫu quan sát.
- “8” đặc trưng đầu vào.
- “1” biến mục tiêu là “Rings”.
- Không có giá trị thiếu sau khi làm sạch dữ liệu gốc.

Theo mô tả chính thức của UCI, tuổi bào ngư được suy ra theo công thức:

- “Age = Rings + 1.5”

Điều này có nghĩa là “Rings” là biến đích trực tiếp trong bài toán, còn tuổi thực tế theo năm có thể được ước lượng bằng cách cộng thêm “1.5”.

Về mặt học thuật, cần phân biệt hai lớp nguồn:

- **Nguồn lưu trữ dữ liệu cho cộng đồng học máy**: UCI Machine Learning Repository, với trích dẫn chuẩn là “Nash, W., Sellers, T., Talbot, S., Cawthorn, A., & Ford, W. (1994). Abalone [Dataset]. UCI Machine Learning Repository. https://doi.org/10.24432/C55C7W”.
- **Nguồn gốc sinh học của dữ liệu**: nghiên cứu của Warwick J. Nash và cộng sự về quần thể bào ngư ở Tasmania, công bố năm 1994.

Việc xác định đúng nguồn gốc dataset là cần thiết vì nhiều người thường nhầm rằng Abalone có một "paper ML gốc", trong khi thực tế đây là bộ dữ liệu sinh học được cộng đồng học máy sử dụng như một benchmark kinh điển cho bài toán hồi quy và phân loại.

1.3 Phát biểu bài toán

Trong đồ án này, nhóm xem bài toán AbaloneAge là một **bài toán hồi quy**, trong đó:

- Đầu vào là các phép đo vật lý của bào ngư.
- Đầu ra là số vòng tuổi “Rings”.

So với cách tiếp cận phân loại theo nhóm tuổi, bài toán hồi quy phù hợp hơn với bản chất liên tục của biến mục tiêu và giúp giữ lại nhiều thông tin hơn trong quá trình học. Sau khi dự đoán “Rings”, có thể quy đổi xấp xỉ sang tuổi thật bằng công thức “Age = Rings + 1.5”.

1.4 Hai hướng tiếp cận xác định tuổi bào ngư

1.4.1 Hướng thực nghiệm sinh học

Đây là phương pháp truyền thống, đồng thời là cơ sở để tạo ra giá trị mục tiêu cho bộ dữ liệu. Quy trình tổng quát gồm:

1. Thu thập mẫu bào ngư.

2. Cắt vỏ qua phần chóp.

3. Mài và nhuộm mẫu để làm rõ các vòng sinh trưởng.

4. Quan sát dưới kính hiển vi.

5. Đếm số vòng và suy ra tuổi.

Ưu điểm của hướng này là có độ tin cậy sinh học cao. Tuy nhiên, nhược điểm là tốn nhiều thời gian, chi phí lớn, mang tính phá hủy mẫu và khó áp dụng trên quy mô rộng.

1.4.2 Hướng mô hình hoá dữ liệu và học máy

Đây là hướng được lựa chọn trong báo cáo. Thay vì can thiệp vật lý vào mẫu vật, mô hình học máy sử dụng các biến đo đạc sẵn có như kích thước và khối lượng để học mối liên hệ với "Rings". Hướng tiếp cận này có các ưu điểm như không phá hủy mẫu vật, dự đoán nhanh sau khi mô hình được huấn luyện, chi phí triển khai thấp hơn và dễ dàng mở rộng cho số lượng lớn mẫu dữ liệu.

Dĩ nhiên, chất lượng dự đoán phụ thuộc mạnh vào dữ liệu đầu vào, quy trình tiền xử lý và mức độ phù hợp của mô hình. Vì vậy, báo cáo không chỉ xây dựng mô hình mà còn phải phân tích dữ liệu và thử nghiệm nhiều chiến lược cải thiện hiệu năng.

1.4.3 So sánh ngắn gọn hai hướng tiếp cận

Tiêu chí	Thực nghiệm sinh học	Mô hình hóa dữ liệu
Độ chính xác sinh học	**Cao** (Phản ánh trực tiếp thực tế khách quan)	**Phụ thuộc vào mô hình** (Dựa trên thuật toán và chất lượng dữ liệu)
Tốc độ xử lý	**Chậm** (Cần thời gian nuôi cấy, phản ứng hóa học)	**Nhanh** (Tính toán bằng CPU/GPU)
Chi phí triển khai	**Cao** (Máy móc, hóa chất, nhân sự chuyên môn)	**Thấp hơn** (Chủ yếu là chi phí phần cứng và phần mềm)
Tính bảo toàn mẫu	**Phá hủy mẫu** (Mẫu thường bị biến đổi sau thí nghiệm)	**Không phá hủy mẫu** (Làm việc trên dữ liệu số)

Khả năng mở rộng	**Hạn chế** (Khó lặp lại quy mô lớn ngay lập tức)	**Tốt** (Dễ dàng chạy lại với quy mô dữ liệu lớn hơn)

Từ so sánh trên, nhóm lựa chọn hướng mô hình hóa dữ liệu làm trọng tâm triển khai của đồ án.

1.5 Mục tiêu và đóng góp chính của đồ án

Bám theo yêu cầu tổng quát của báo cáo, đồ án hướng tới các mục tiêu sau:

- Phân tích đặc điểm của bộ dữ liệu Abalone và làm rõ bản chất bài toán
- Xây dựng pipeline tiền xử lý phù hợp cho dữ liệu bảng có cả biến số và biến phân loại
- Thử nghiệm các mô hình hồi quy và so sánh hiệu năng
- Đánh giá tác động của các bước cải tiến như preprocessing, feature engineering, tuning và ensemble
- Rút ra nhận xét về yếu tố nào thực sự giúp cải thiện kết quả dự đoán

Theo định hướng này, phần thực nghiệm của báo cáo sẽ được tổ chức như một chuỗi giả thuyết kiểm chứng dần, thay vì chỉ liệt kê mô hình. Cách trình bày này cũng phù hợp với tinh thần của paper tham khảo mà nhóm đang học theo.

Ở giai đoạn hiện tại, báo cáo đã ghi nhận một số đóng góp ban đầu:

- Xây dựng được mốc baseline bằng Random Forest để làm cơ sở so sánh.
- Kiểm tra ảnh hưởng của các chiến lược preprocessing và nhận thấy mức cải thiện còn hạn chế.
- Chứng minh được rằng feature engineering thủ công mang lại cải thiện rõ hơn preprocessing thuần túy.
- Tạo nền kết quả định lượng để phát triển tiếp các phần benchmark nhiều mô hình, tuning sâu hơn và ensemble.

1.5.1. Động lực nghiên cứu

Bên cạnh mục tiêu xây dựng một hệ thống mô hình dự đoán chính xác số vòng tuổi Rings, đồ án còn hướng đến việc xác định sâu hơn những yếu tố nào thực sự giúp cải thiện khả năng dự đoán trên bộ dữ liệu Abalone. Vì vậy, nhóm không chỉ đơn thuần thực hiện quá trình benchmark (đánh giá đối chuẩn) các thuật toán học máy, mà còn tổ chức một chuỗi thực nghiệm có hệ thống. Chuỗi thực nghiệm này được xây dựng dựa trên từng giả thuyết cụ thể về đặc trưng dữ liệu, kỹ thuật tiền xử lý, phương pháp chọn lọc đặc trưng và các thuật toán học máy, nhằm mang lại một góc nhìn toàn diện và có tính diễn giải cao.

1.5.2. Các câu hỏi nghiên cứu trọng tâm

Để hiện thực hóa động lực trên, đồ án tập trung giải quyết 4 câu hỏi nghiên cứu cốt lõi sau:

1. Trong số các phép đo vật lý của bào ngư, đặc trưng nào mang tín hiệu sinh học mạnh nhất và có liên hệ mật thiết nhất với sự hình thành vòng tuổi?

2. Sự xuất hiện của các giá trị ngoại lệ (outliers) và độ lệch phân phối ở các biến khối lượng có đòi hỏi sự can thiệp mạnh mẽ bằng các phương pháp chuẩn hóa phức tạp hay không?

3. Việc ứng dụng Feature Engineering (Khai phá đặc trưng) dựa trên ý nghĩa sinh học/hình học có mang lại sự cải thiện vượt trội hơn so với các phương pháp tiền xử lý (Preprocessing) thuần túy?

4. Giữa các họ mô hình học máy (Tuyến tính, Cây quyết định, Kernel, Mạng nơ-ron), mô hình nào thể hiện khả năng tổng quát hóa (generalization) tốt nhất khi đối chiếu chênh lệch sai số giữa tập huấn luyện (Cross-Validation) và tập kiểm thử (Test)?

CHƯƠNG 2: PHÂN TÍCH BÀI TOÁN VÀ DỮ LIỆU

2.1. Mô tả dữ liệu

Bộ dữ liệu Abalone gồm 8 thuộc tính đầu vào và 1 biến mục tiêu. Các biến được sử dụng trong đồ án bao gồm:

Biến	Kiểu dữ liệu	Ý nghĩa	Đơn vị
Sex	Phân loại	Giới tính (M: Đực, F: Cái, I: Chưa trưởng thành)	Danh mục
Length	Liên tục	Chiều dài lớn nhất của vỏ	mm
Diameter	Liên tục	Đường kính vuông góc với chiều dài	mm
Height	Liên tục	Chiều cao của bào ngư khi còn trong vỏ	mm
Whole Weight	Liên tục	Khối lượng toàn phần của bào ngư	gram
Shucked Weight	Liên tục	Khối lượng phần thịt (trọng lượng sau khi bỏ vỏ)	gram
Viscera Weight	Liên tục	Khối lượng nội tạng sau khi chảy máu	gram

Shell Weight	Liên tục	Khối lượng vỏ (sau khi đã được sấy khô)	gram
Rings	Số nguyên	Số vòng trên vỏ (Biến mục tiêu) dùng để suy ra tuổi	Vòng

Từ mô tả chính thức của UCI và hướng phân tích của đồ án, có thể rút ra một số nhận định ban đầu:

- Dữ liệu không có giá trị thiếu
- Chỉ có một biến phân loại là “Sex”, còn lại chủ yếu là biến số liên tục
- Các biến về khối lượng và kích thước có khả năng tương quan với “Rings”
- Mối quan hệ giữa đầu vào và biến mục tiêu có thể không hoàn toàn tuyến tính
- Một số biến có thể xuất hiện độ lệch phân phối hoặc ngoại lệ, nên cần được kiểm tra ở bước EDA

Những nhận định này là cơ sở để nhóm triển khai các bước tiếp theo như trực quan hóa dữ liệu, so sánh chiến lược tiền xử lý và xây dựng đặc trưng mới.

2.2. Những thách thức chính của bài toán

So với nhiều bài toán hồi quy chuẩn trên dữ liệu bảng, bài toán AbaloneAge có một số khó khăn đáng chú ý:

- Số lượng đặc trưng không lớn, nên hiệu quả mô hình phụ thuộc mạnh vào chất lượng biểu diễn của từng biến.
- Dữ liệu có sự kết hợp giữa biến phân loại và biến số liên tục, nên cần lựa chọn pipeline tiền xử lý phù hợp.

- Các biến khối lượng và kích thước có thể tương quan mạnh với nhau, làm xuất hiện hiện tượng dư thừa thông tin.
- Biến mục tiêu “Rings” là số nguyên nhưng được dự đoán dưới góc nhìn hồi quy, nên mô hình cần vừa học tốt xu hướng chung vừa giữ sai số ở mức thấp.
- Bài toán có khả năng chứa quan hệ phi tuyến giữa kích thước, khối lượng và tuổi, khiến các mô hình tuyến tính đơn giản có thể bị giới hạn.

Từ các đặc điểm trên, báo cáo ưu tiên đánh giá mô hình bằng các chỉ số sai số như “RMSE”, “MAE”, “MSE” và “R2”, đồng thời phân tích riêng tác động của preprocessing và feature engineering lên chất lượng dự đoán.

2.3. Định hướng phân tích dữ liệu khám phá

Ở giai đoạn EDA, báo cáo sẽ tập trung trả lời các câu hỏi sau:

1. Phân phối của biến mục tiêu “Rings” có trải đều hay tập trung ở một vài mức tuổi?

2. Biến “Sex” có ảnh hưởng đáng kể đến “Rings” hay không?

3. Các biến kích thước và khối lượng có mối tương quan tuyến tính mạnh đến đâu với biến mục tiêu?

4. Có tồn tại ngoại lệ hoặc phân phối lệch ở các biến đầu vào không?

5. Feature engineering có thể khai thác thêm thông tin gì từ các biến vật lý gốc?

Từ đây, phần thực nghiệm ở các chương sau sẽ được tổ chức theo hướng:

- Xây dựng mốc baseline.
- So sánh preprocessing.
- Kiểm tra hiệu quả của feature engineering.
- Mở rộng sang nhiều mô hình hồi quy.
- Tối ưu và kết hợp mô hình khi cần thiết.

Theo kết quả hiện có, ba phát hiện định lượng đầu tiên đã định hình hướng triển khai tiếp theo:

- Tuning Random Forest giúp giảm “RMSE” từ “2.1946” xuống “2.1717”.

- Thay đổi preprocessing chỉ tạo ra khác biệt nhỏ, với “RMSE” dao động quanh “2.185 - 2.187”.

- Feature engineering giúp giảm “RMSE” từ “2.1844” xuống “2.1542”, tốt hơn mức cải thiện thu được từ preprocessing.

Điều này cho thấy phần tiếp theo của báo cáo nên ưu tiên khai thác đặc trưng và so sánh mô hình trên cùng một khung đánh giá nhất quán, thay vì kỳ vọng quá nhiều vào riêng bước chuẩn hóa dữ liệu.

2.4. Kết quả khám phá dữ liệu từ notebook 01

Dựa trên notebook “**01_kham_pha_du_lieu.ipynb**”, nhóm thu được các kết quả EDA quan trọng như sau.

2.4.1 Kích thước và cấu trúc dữ liệu

Tập dữ liệu sau khi nạp có kích thước “4177” dòng và “9” cột. Trong đó:

- “1” biến phân loại: “Sex”.
- “7” biến số thực: “Length”, “Diameter”, “Height”, “WholeWeight”, “ShuckedWeight”, “VisceraWeight”, “ShellWeight”.
- “1” biến mục tiêu nguyên: “Rings”.

Toàn bộ các cột đều có đủ “4177” giá trị hợp lệ. Notebook cũng kiểm tra lại chất lượng dữ liệu và cho thấy:

- Tổng số giá trị thiếu: “0”.
- Số dòng trùng lặp: “0”.

Kết quả này rất thuận lợi cho bài toán hồi quy, vì nhóm không cần xử lý missing value hay loại bỏ nhiều điểm dữ liệu trước khi huấn luyện.

2.4.2 Phân phối biến mục tiêu “Rings”

Thống kê mô tả của **biến mục tiêu** trong notebook cho thấy:

- Giá trị trung bình: “9.9337”.
- Trung vị: “9”.
- Độ lệch chuẩn: “3.2242”.
- Giá trị nhỏ nhất: “1”.
- Giá trị lớn nhất: “29”.
- Độ lệch phân phối “skewness”: “1.1141”.

Như vậy, “Rings” có xu hướng lệch phải nhẹ, nghĩa là phần lớn mẫu tập trung ở vùng tuổi thấp đến trung bình, trong khi vẫn tồn tại một nhóm cá thể có số vòng khá cao. Đây là một dấu hiệu quan trọng, vì nó cho thấy mô hình cần dự đoán tốt ở vùng trung tâm nhưng vẫn không được bỏ qua các cá thể già hơn nằm ở phần đuôi phân phối.

2.4.3 Vai trò của biến “Sex”

Notebook EDA đã phân tích tần suất và phân phối “Rings” theo từng nhóm “Sex”. Kết quả tổng hợp như sau:

Nhóm Sex	Số mẫu	Mean Rings	Median Rings	Độ lệch chuẩn (Std)
F (Cái)	1,307	11.13	10	3.10
I (Chưa trưởng thành)	1,342	7.89	8	2.51
M (Đực)	1,528	10.71	10	03.03

Từ bảng trên có thể thấy:

- Nhóm “I” có số vòng trung bình thấp nhất, phù hợp với ý nghĩa "infant".
- Nhóm “F” có số vòng trung bình cao nhất trong ba nhóm.
- Sự khác biệt này cho thấy “Sex” không phải một biến dư thừa, mà có khả năng mang thông tin dự báo hữu ích.

Vì vậy, quyết định giữ lại và mã hóa “Sex” trong pipeline là hoàn toàn hợp lý.

Để đánh giá xem giới tính có phải là một yếu tố phân loại tốt cho sự phát triển của bào ngư hay không, nhóm nghiên cứu đã sử dụng biểu đồ vĩ cầm (Violin Plot) để quan sát sự phân bố của tất cả các đặc trưng vật lý theo từng nhóm giới tính.

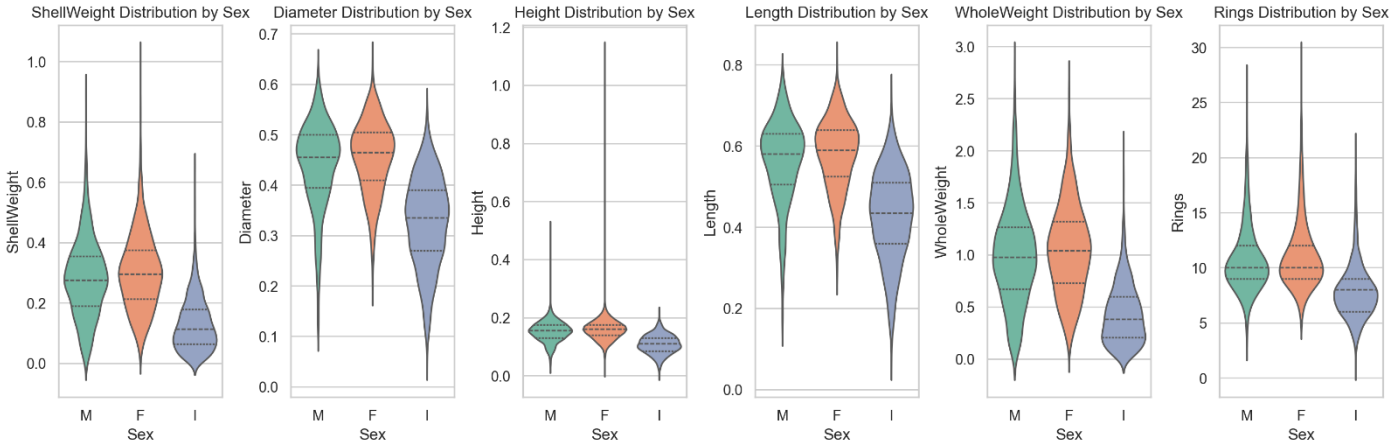

Hình 1. Biểu đồ violin thể hiện phân bố các đặc trưng

Quan sát từ hình trên, nhóm rút ra những nhận định mang tính định hướng cho việc xây dựng mô hình:

- **Sự tách biệt của nhóm Bào ngư non (Infant - I):** Nhóm I có sự khác biệt rất rõ rệt. Phân phối của nhóm này (màu xanh lá) luôn nằm ở vùng có giá trị thấp hơn hẳn trên mọi phương diện từ kích thước (Length, Diameter), khối lượng cho đến biến mục tiêu là số vòng tuổi (Rings). Điều này cho thấy biến Sex sẽ cung cấp một tín hiệu rất mạnh để mô hình nhận diện nhóm bào ngư chưa trưởng thành.
- **Sự chồng lấn giữa Bào ngư Đực (M) và Cái (F):** Ngược lại với nhóm I, phân phối của nhóm M và F gần như giống hệt nhau về cả hình dáng lẫn trung vị. Hiện tượng này ngầm chỉ ra rằng: nếu chỉ dựa vào kích thước và khối lượng vật lý tĩnh, mô hình sẽ cực kỳ khó phân biệt giữa bào ngư đực và cái.
- **Tác động đến mô hình dự đoán:** Mặc dù biến Sex mang lại thông tin phân cụm tốt cho nhóm Infant, nhưng do sự chồng lấn quá lớn giữa Male và Female, nó khó có thể trở thành đặc trưng quan trọng nhất (Top 1 Feature Importance). Thay vào đó, các biến liên tục như ShellWeight sẽ đóng vai trò quyết định hơn trong việc tinh chỉnh số tuổi.

2.4.4. Ngoại lệ và độ lệch phân phối

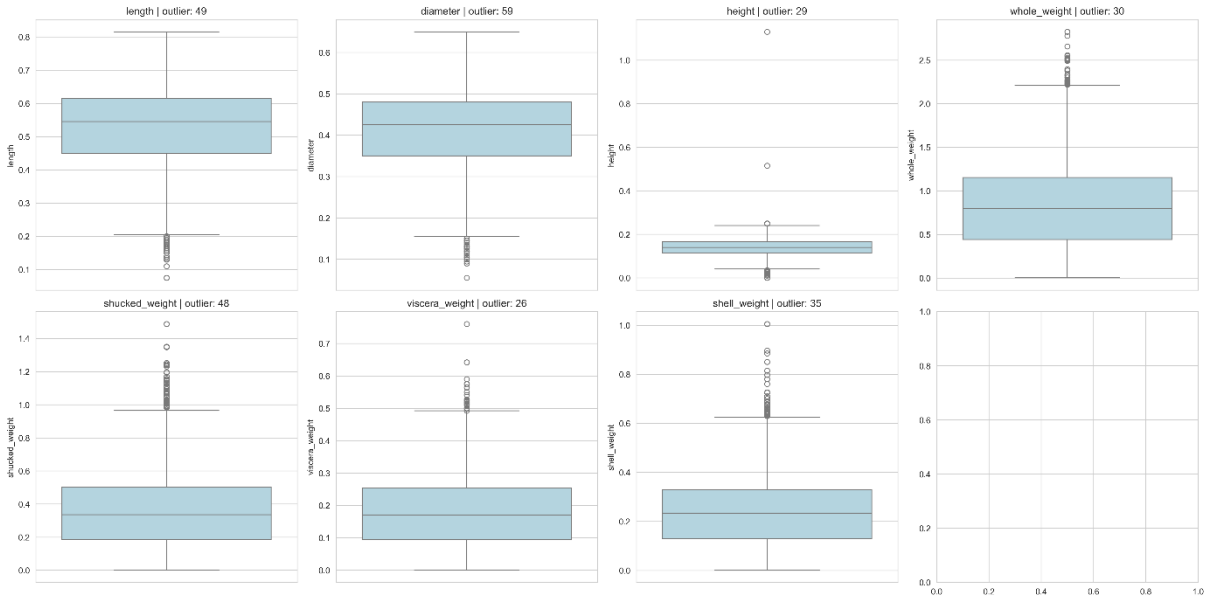

Hình 2. Biểu đồ boxplot thể hiện phân bố và số lượng ngoại lệ

Nhóm sử dụng boxplot và quy tắc IQR để nhận diện ngoại lệ. Kết quả cho thấy các biến đều có một tỷ lệ outlier nhất định, trong đó nổi bật là:

Biến	Tỷ lệ Outlier (%)
Diameter	1.41%
Length	1.17%
ShuckedWeight	1.15%
ShellWeight	0.84%
WholeWeight	0.72%
Height	0.69%
VisceraWeight	0.62%

Nhận xét từ EDA cho thấy:

- Outlier không quá cực đoan ở từng biến đầu vào, nhưng xuất hiện ở hầu hết các biến quan trọng.
- Các biến khối lượng có độ phân tán tương đối lớn.
- Biến “Height” có giá trị nhỏ nhất bằng “0.0”, cần được quan sát cẩn thận vì về trực giác đây là giá trị bất thường.

Thay vì loại bỏ outlier ngay từ đầu, nhóm chọn chiến lược thận trọng hơn: giữ nguyên dữ liệu gốc cho baseline, đồng thời tạo thêm một phiên bản dữ liệu "robust_log_scaled" để kiểm tra xem log-transform và "RobustScaler" có cải thiện chất lượng dự đoán hay không.

2.4.5.Tương quan giữa các biến với "Rings"

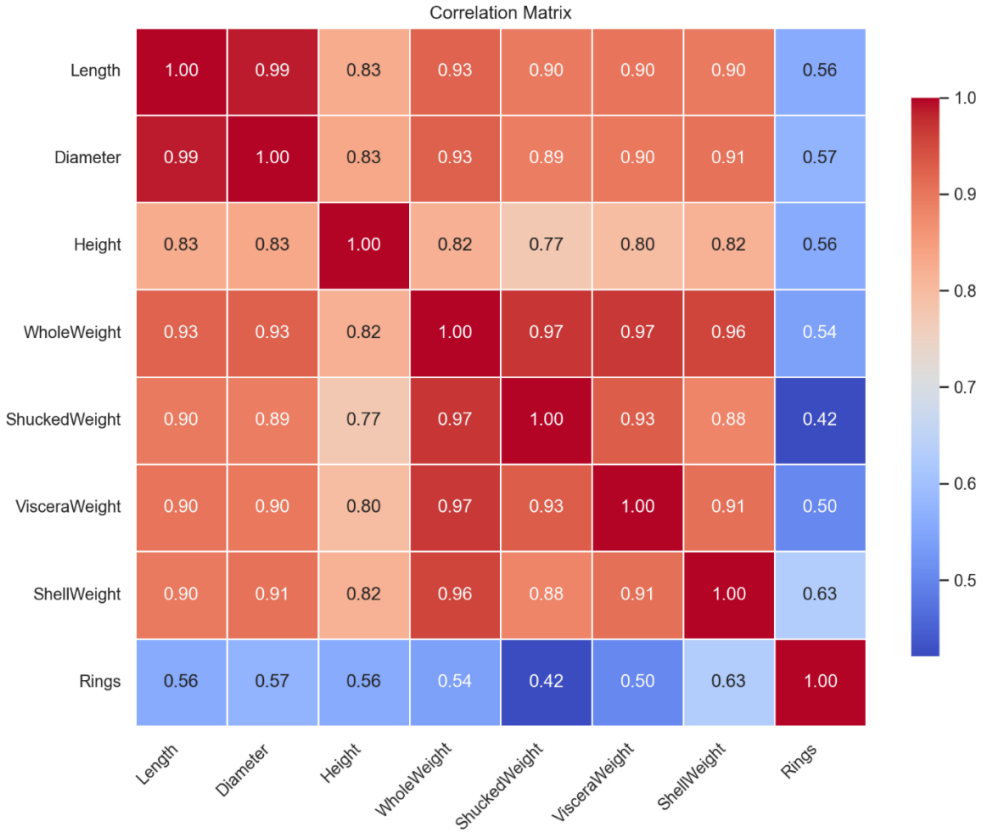

Hình 3. Ma trận tương quan giữa các biến

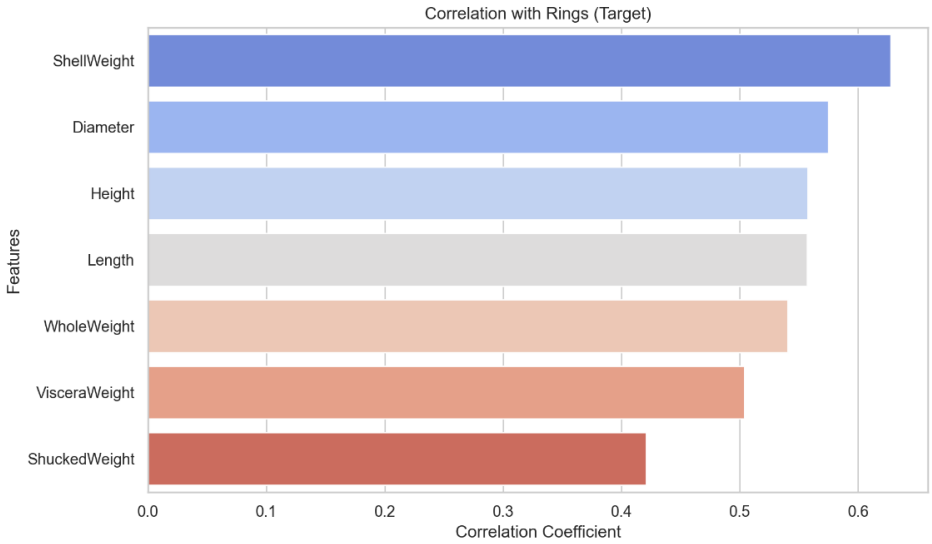

Hình 4. Biểu đồ thanh thể hiện hệ số tương quan với biến mục tiêu

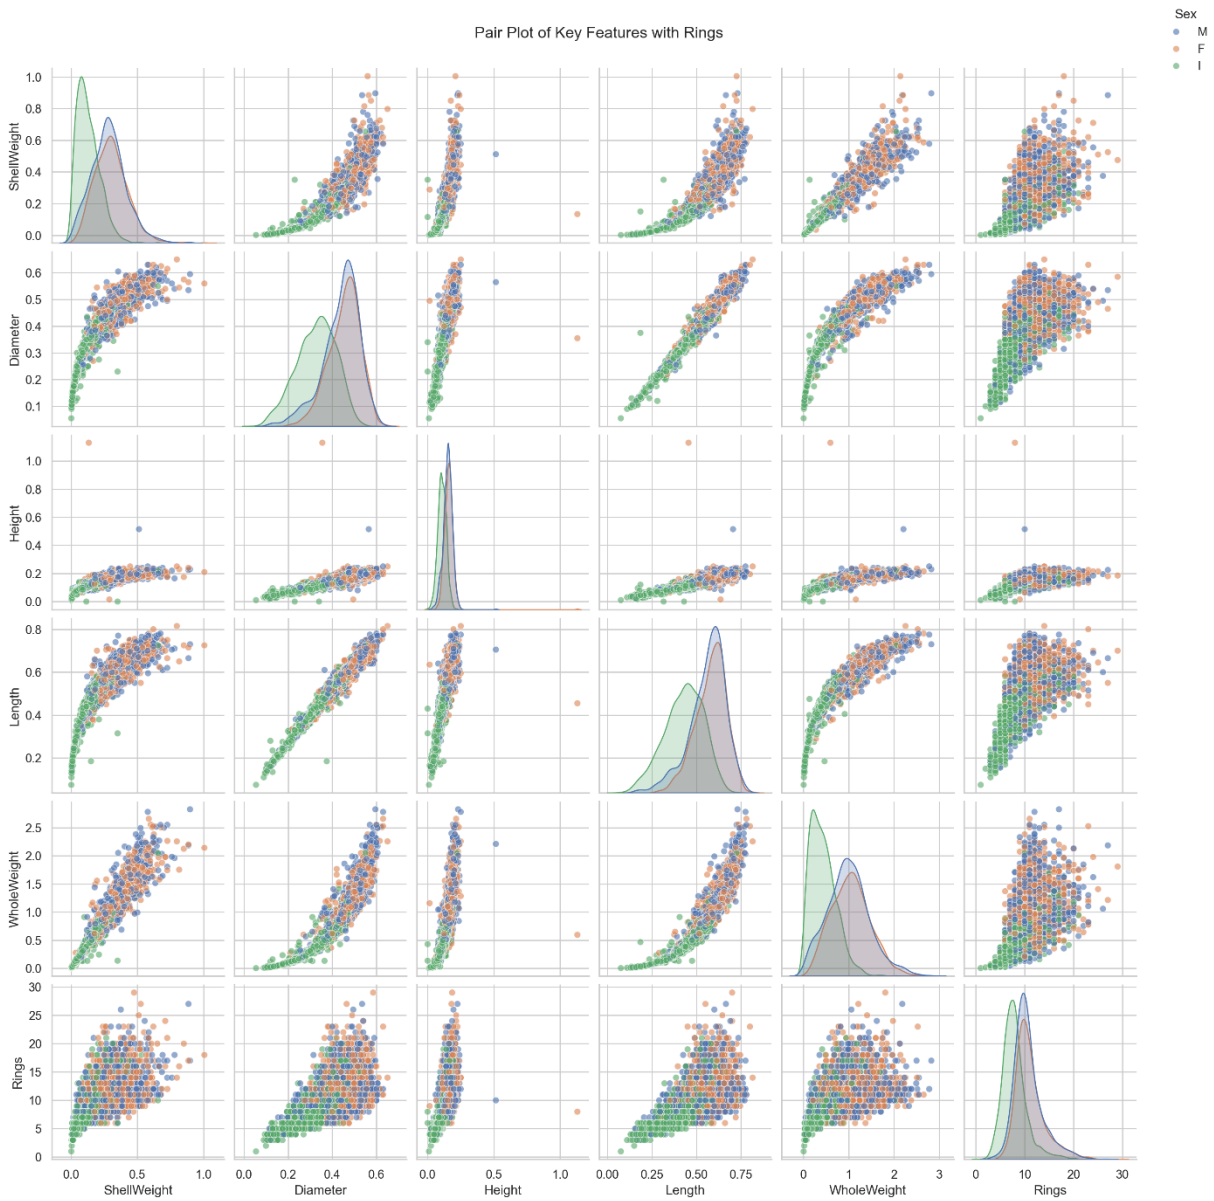

Hình 5. Biểu đồ pairplot thể hiện mối quan hệ giữa các đặc trưng chính

Ma trận tương quan trong notebook chỉ ra các biến có quan hệ mạnh nhất với "Rings" như sau:

Biến	Tương quan với Rings
ShellWeight	0.63
Diameter	0.57
Height	0.56
Length	0.56
WholeWeight	0.54
VisceraWeight	0.50
ShuckedWeight	0.42

Từ đây, nhóm rút ra hai điểm đáng chú ý:

- “ShellWeight” là biến có tương quan tuyến tính mạnh nhất với “Rings”, cho thấy khối lượng vỏ khô là một tín hiệu sinh học quan trọng cho bài toán tuổi.
- Các biến kích thước và khối lượng đều có tương quan dương mức trung bình đến khá, tức là càng lớn và càng nặng thì bào ngư có xu hướng có nhiều vòng hơn.

Tuy nhiên, các hệ số tương quan chưa quá cao đến mức có thể giải thích hoàn toàn bài toán bằng mô hình tuyến tính đơn giản. Điều này cũng giải thích vì sao nhóm cần thử thêm các mô hình phi tuyến như Random Forest, Gradient Boosting, SVR và MLP.

Phát triển từ EDA	Bằng chứng	Hàm ý	Quyết định bước tiếp theo
Nhóm bào ngư non (I) có phân phối Rings tách biệt hẳn so với M và F.	Bảng thống kê Rings và Biểu đồ Violin Plot theo biến Sex.	Sex mang tín hiệu dự báo phân cụm rất tốt, không phải là biến dư thừa.	Giữ lại biến Sex và thực hiện One-Hot Encoding.
Các biến khối lượng (Weight) có độ lệch phân phối và tỷ lệ outlier từ 0.6% đến 1.15%.	Histogram và phân tích Boxplot / IQR.	Mô hình tuyến tính/mạng nơ-ron có thể bị nhiễu; cần kiểm tra hiệu quả của phép biến đổi làm mượt dữ liệu.	Không cắt bỏ outlier thô bạo. Tạo nhánh dữ liệu robust_log_scaled để kiểm chứng.
ShellWeight, Diameter, Height có tương quan dương khá tốt với Rings (0.56 - 0.63).	Ma trận tương quan (Correlation Heatmap).	Quan hệ giữa kích thước/khối lượng và tuổi có thể mang tính phi tuyến.	Ưu tiên thử nghiệm tính hiệu quả của nhóm mô hình Tree-based, SVR và MLP.

2.5. Giả thuyết rút ra từ phân tích dữ liệu

Từ những kết quả khám phá dữ liệu (EDA), nhóm thiết lập 5 giả thuyết nền tảng để định hướng cho toàn bộ quá trình thực nghiệm ở các chương sau:

1. **Giả thuyết 1:** Biến phân loại Sex là một đặc trưng hữu ích giúp phân tách nhóm bào ngư chưa trưởng thành, do đó cần được giữ lại và mã hóa phù hợp.
2. **Giả thuyết 2:** Kỹ thuật chuẩn hóa tiêu chuẩn (standard_scaled) sẽ tối ưu hóa sự hội tụ cho các mô hình nhạy cảm với thang đo như SVR, KNN hay Multi-layer Perceptron.
3. **Giả thuyết 3:** Đối với các biến số có phân phối lệch và chứa ngoại lệ (như các biến khối lượng), kỹ thuật chuẩn hóa kháng nhiễu (robust_log_scaled) sẽ giúp mô hình hoạt động ổn định hơn so với việc loại bỏ hoàn toàn các điểm dữ liệu này.
4. **Giả thuyết 4:** Do giới hạn về mức độ tương quan tuyến tính của các biến vật lý, các mô hình phi tuyến (Non-linear models) sẽ đem lại hiệu năng dự báo vượt trội hơn nhóm mô hình tuyến tính truyền thống.
5. **Giả thuyết 5:** Việc khai phá và thiết lập các đặc trưng mới (Feature Engineering) mang ý nghĩa sinh học và hình học có thể tạo ra những tín hiệu hữu ích bổ sung mà bước chuẩn hóa dữ liệu thuần túy không làm được.

CHƯƠNG 3: PHƯƠNG PHÁP VÀ QUÁ TRÌNH THỰC NGHIỆM

3.1. Quy trình triển khai tổng thể

Toàn bộ phần thực nghiệm của đồ án được chia thành 5 notebook chính, tương ứng với một quy trình nghiên cứu tuần tự:

1. "01_kham_pha_du_lieu.ipynb": hiểu dữ liệu, phát hiện vấn đề và rút ra định hướng xử lý.
2. "02_tien_xu_ly_du_lieu.ipynb": xây dựng các phiên bản dữ liệu sạch và phù hợp với từng nhóm mô hình.
3. "03_huan_luyen_mo_hinh.ipynb": huấn luyện 10 mô hình baseline và đánh giá bằng "5-fold Cross-validation".
4. "04_danh_gia_mo_hinh.ipynb": kiểm tra khả năng tổng quát hóa trên tập test.
5. "05_thu_nghiem_bo_sung.ipynb": tối ưu hóa, so sánh các phiên bản dữ liệu, tuning và thử ensemble.

Cách tổ chức này giúp báo cáo không chỉ trình bày kết quả cuối cùng, mà còn thể hiện được quá trình nghiên cứu, suy luận và kiểm chứng giả thuyết của nhóm qua từng giai đoạn.

3.2. Giai đoạn 1: Khám phá dữ liệu và hình thành giả thuyết

Ở notebook đầu tiên, mục tiêu của nhóm không phải là huấn luyện mô hình ngay, mà là trả lời các câu hỏi nền tảng:

- Dữ liệu có sạch hay không.

- Biến nào có khả năng dự báo mạnh.

- Có tồn tại độ lệch phân phối hoặc ngoại lệ đáng chú ý hay không.

- Bài toán có xu hướng tuyến tính hay phi tuyến.

Kết quả EDA đã tạo ra bộ giả thuyết nghiên cứu ban đầu:

- “Sex” là biến hữu ích nên phải được mã hóa.

- Các biến khối lượng mang tín hiệu mạnh và có thể tiếp tục khai thác bằng feature engineering.

- Quan hệ giữa đầu vào và “Rings” không hoàn toàn tuyến tính.

- Cần thử song song mô hình tuyến tính, mô hình kernel, mô hình cây và mạng nơ-ron.

Nhờ đó, notebook EDA đóng vai trò như nền tảng ra quyết định cho toàn bộ các giai đoạn sau, thay vì chỉ là bước minh họa biểu đồ.

3.3. Giai đoạn 2: Tiền xử lý dữ liệu

Notebook “**02_tien_xu_ly_du_lieu.ipynb**” hiện thực hóa các kết luận từ EDA thành pipeline xử lý dữ liệu cụ thể.

3.3.1. Làm sạch dữ liệu

Nhóm sử dụng các hàm trong “src/data/clean_data.py” để:

- Kiểm tra lại missing values.

- Kiểm tra và loại bỏ duplicate nếu có.

- Chuẩn hóa định dạng cột phân loại.

Sau bước này, dữ liệu vẫn giữ nguyên kích thước “4177 x 9”, xác nhận rằng bộ dữ liệu đầu vào đã khá sạch ngay từ đầu.

3.3.2. Chia dữ liệu train/test

Nhóm chia dữ liệu theo tỷ lệ “70/30” với “random_state = 42”, thu được:

- “X_train”: “(2923, 8)”

- “X_test”: “(1254, 8)”

- “y_train”: “(2923,)”

- “y_test”: “(1254,)”

Việc cố định seed giúp kết quả thực nghiệm có thể tái lập.

3.3.3. Tạo ba phiên bản dữ liệu

Một điểm quan trọng trong notebook 02 là nhóm không ép mọi mô hình dùng chung một phiên bản dữ liệu, mà thiết kế ba nhánh xử lý khác nhau:

Phiên bản	Cách xử lý	Mục đích sử dụng chính
encoded_only	One-Hot Encoding cho Sex, giữ nguyên các biến số.	Phù hợp cho mô hình cây (Random Forest, XGBoost) vì chúng không nhạy cảm với thang đo.
standard_scaled	One-Hot Sex + StandardScaler ($\mu=0,\sigma=1$) cho biến số.	Phù hợp cho các mô hình nhạy cảm với scale như Linear Regression, SVM, hoặc KNN.
robust_log_scaled	log1p cho nhóm khối lượng + One-Hot + RobustScaler.	Xử lý dữ liệu bị lệch (skewed) và giảm ảnh hưởng của các điểm dị biệt (outliers).

Sau khi mã hóa One-Hot cho “Sex”, cả ba phiên bản đều có “10” cột đầu vào.

3.3.4. Kiểm soát rò rỉ dữ liệu

Một điểm thể hiện sự cẩn thận trong triển khai là mọi encoder và scaler đều chỉ được "fit" trên tập train, sau đó mới "transform" sang tập test. Quy trình này tránh hiện tượng data leakage, bảo đảm rằng mô hình không vô tình nhìn thấy thông tin của tập kiểm tra ở bước tiền xử lý.

3.3.5. Lưu dữ liệu trung gian

Các tập dữ liệu được lưu vào "data/interim" và "data/processed" để các notebook sau có thể dùng lại trực tiếp. Cách làm này có ba lợi ích:

- Giảm lặp lại thao tác xử lý.
- Giúp các bước huấn luyện và đánh giá chạy độc lập hơn.
- Hỗ trợ việc tái hiện toàn bộ quy trình khi cần báo cáo hoặc kiểm tra lại.

3.4. Giai đoạn 3: Huấn luyện 10 mô hình baseline

Notebook "**03_huan_luyen_mo_hinh.ipynb**" là giai đoạn trọng tâm đầu tiên để lượng hóa hiệu năng của các thuật toán.

3.4.1. Mười mô hình hồi quy được sử dụng

Nhóm triển khai đủ 10 mô hình hồi quy bắt buộc:

STT	Mô hình	Phiên bản dữ liệu dùng cho baseline	Lý do lựa chọn
1	LinearRegression	standard_scaled	Cần chuẩn hóa để các hệ số (w) không bị ảnh hưởng bởi đơn vị khác nhau.
2	KNeighborsRegressor	standard_scaled	Bắt buộc; KNN tính khoảng cách, nếu không scale biến lớn sẽ áp đảo biến nhỏ.
3	RidgeRegression	standard_scaled	Tương tự Linear, chuẩn hóa giúp việc phạt (regularization) công bằng giữa các biến.

4	DecisionTreeRegressor	encoded_only	Các thuật toán chia nhánh dựa trên ngưỡng, không quan tâm đến độ lớn (scale) của biến.
5	RandomForestRegressor	encoded_only	Mô hình Ensemble dựa trên cây, hoạt động tốt nhất trên dữ liệu gốc.
6	GradientBoostingRegressor	encoded_only	Hoạt động hiệu quả với cơ chế boosting trên cây quyết định.
7	SGDRegressor	standard_scaled	Cần thiết để Gradient Descent hội tụ nhanh và không bị dao động quá mức.
8	SVR	standard_scaled	Sử dụng Kernel để tính toán khoảng cách, rất nhạy cảm với scale dữ liệu.
9	LinearSVR	standard_scaled	Tương tự SVR nhưng tối ưu cho hàm tuyến tính, cần chuẩn hóa để hội tụ tốt hơn.
10	MLPRegressor	standard_scaled	Mạng thần kinh nhân tạo yêu cầu đầu vào nhỏ và đồng nhất để tránh "cháy" hàm kích hoạt.

Việc gán phiên bản dữ liệu theo bản chất thuật toán là một điểm mạnh của đồ án. Nếu tất cả mô hình bị ép dùng chung một kiểu preprocess, kết quả so sánh sẽ dễ trở nên thiếu công bằng.

3.4.2. Phương pháp đánh giá

Tất cả mô hình baseline đều được đánh giá bằng:

- “5-fold Cross-validation”.

- “KFold(n_splits=5, shuffle=True, random_state=42)”.

- các metric: “MSE”, “RMSE”, “RSE”, “MAE”, “execution_time_sec”.

Ngoài các metric tổng hợp, notebook còn lưu dự đoán OOF để phục vụ các bước so sánh sâu hơn ở giai đoạn tối ưu hóa.

3.4.3. Kết quả baseline trên cross-validation

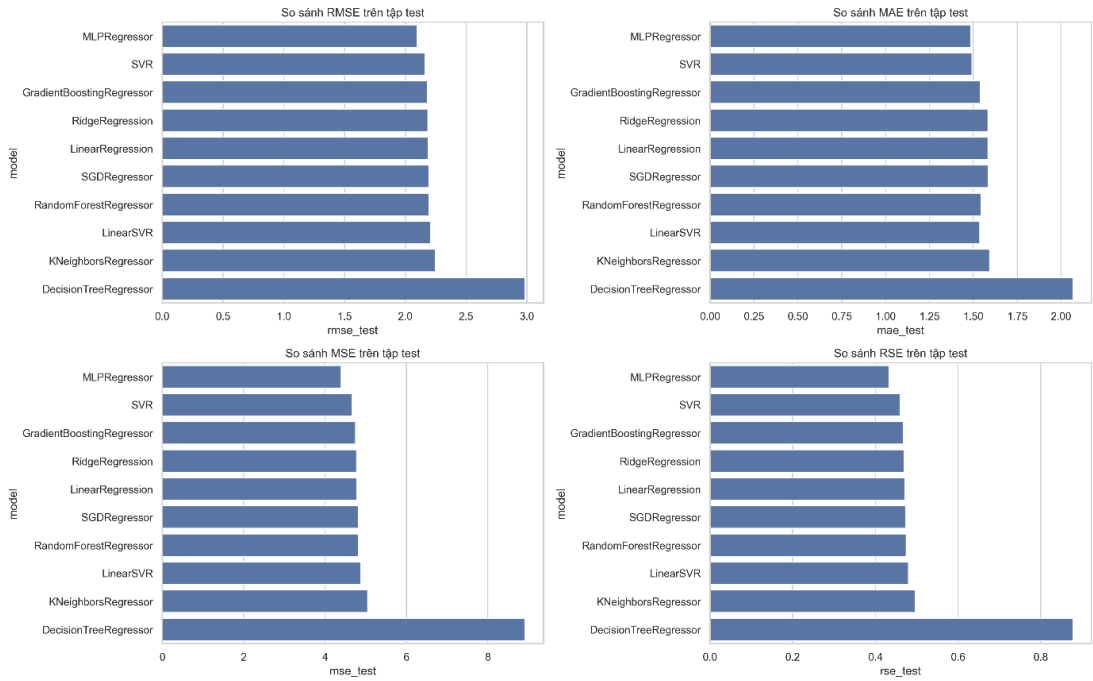

Hình 6. So sánh hiệu suất các mô hình hồi quy trên cross-validation

Mô hình	Dataset	RMSE	MAE	MSE	RSE	Thời gian (s)
GradientBoostingRegressor	encoded_only	2.1717	1.5304	4.7163	4.497	1.3256
SVR	standard_scaled	2.1806	1.4823	4.7549	4.534	1.4044
MLPRegressor	standard_scaled	2.2146	1.4979	4.9047	4.677	7.4329
RandomForestRegressor	encoded_only	2.2198	1.5640	4.9276	4.699	2.3422
LinearRegression	standard_scaled	2.2622	1.6026	5.1175	4.880	5.2685
RidgeRegression	standard_scaled	2.2625	1.6020	5.1189	4.881	295
SGDRegressor	standard_scaled	2.2901	1.6114	5.2445	5.001	493
LinearSVR	standard_scaled	2.2913	1.5672	5.2501	5.007	466
KNeighborsRegressor	standard_scaled	2.3393	1.6213	5.4723	5.218	3.4916

DecisionTreeRegressor	encoded_only	3.0191	2.0859	9.1150	8.692	1.312

3.4.4. Nhận xét từ baseline CV

Từ bảng trên, nhóm rút ra một số nhận xét quan trọng:

- “GradientBoostingRegressor” là mô hình baseline tốt nhất theo “RMSE”, “MSE” và “RSE”.

- “SVR” cho “MAE” thấp nhất, chứng tỏ mô hình này kiểm soát sai số tuyệt đối khá tốt.

- “MLPRegressor” chưa đứng đầu trong CV, nhưng nằm trong nhóm rất cạnh tranh.

- “DecisionTreeRegressor” kém xa phần còn lại, cho thấy cây đơn lẻ không đủ mạnh cho bài toán này.

- “LinearRegression” và “RidgeRegression” có kết quả gần như tương đương, phản ánh rằng regularization tuyến tính chỉ cải thiện rất ít khi chưa thay đổi không gian đặc trưng.

Kết quả baseline cũng củng cố kết luận từ EDA: bài toán AbaloneAge có xu hướng cần mô hình phi tuyến hoặc mô hình có năng lực biểu diễn mạnh hơn.

3.5. Giai đoạn 4: Đánh giá khả năng tổng quát hóa trên tập test

Notebook “04_danh_gia_mo_hinh.ipynb” dùng các mô hình đã huấn luyện trên toàn bộ tập train để dự đoán trên tập test và kiểm tra khả năng tổng quát hóa thực sự.

3.5.1. Kết quả baseline trên tập test

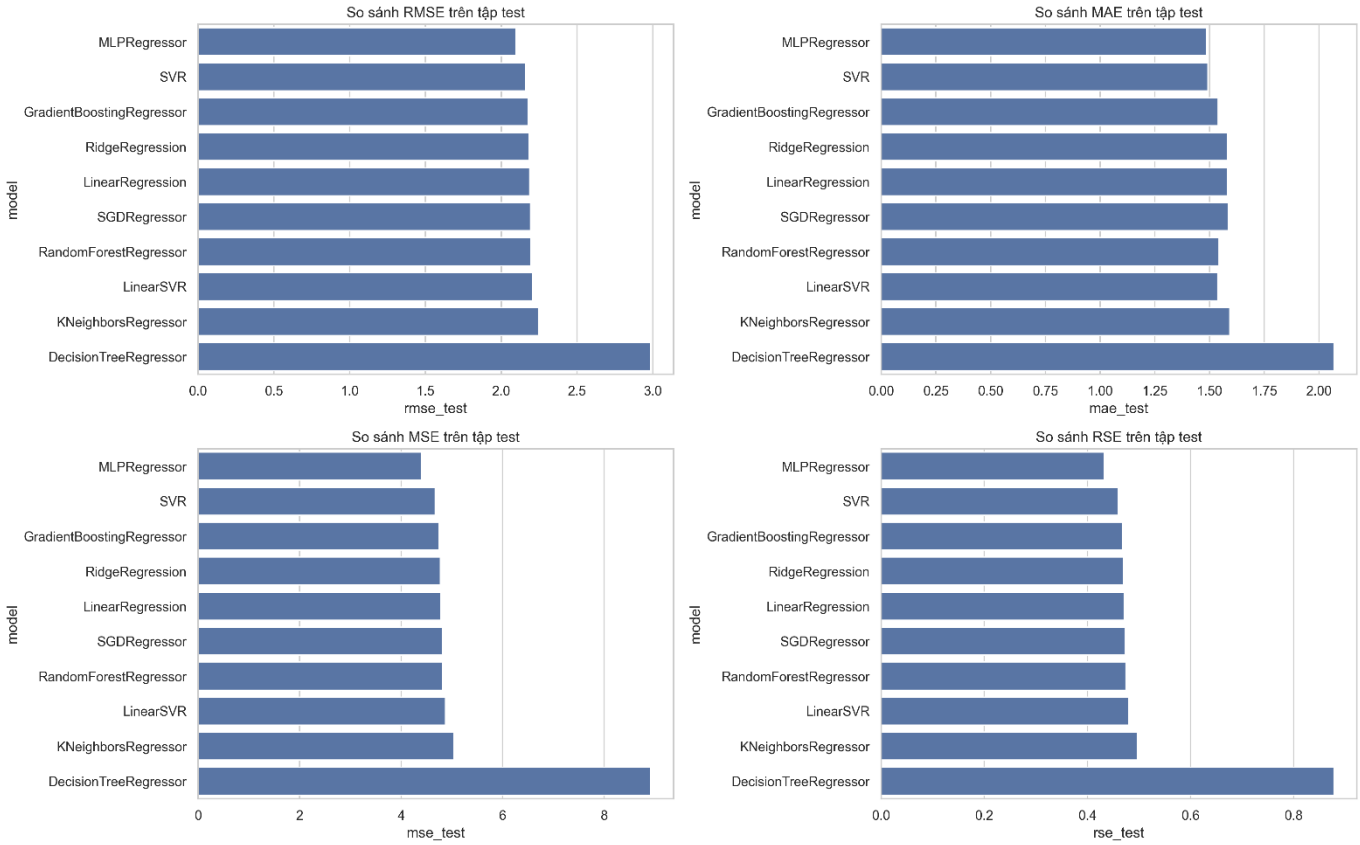

Hình 7. So sánh hiệu suất các mô hình hồi quy trên tập test

Mô hình	Dataset	RMSE test	MAE test	MSE test	RSE test
MLPRegressor	standard_scaled	2.0970	1.4871	4.3976	4.331
SVR	standard_scaled	2.1609	1.4914	4.6694	4.598
GradientBoostingRegressor	encoded_only	2.1800	1.5400	4.7523	4.680
RidgeRegression	standard_scaled	2.1853	1.5829	4.7757	4.703
LinearRegression	standard_scaled	2.1874	1.5832	4.7848	4.712
SGDRegressor	standard_scaled	2.1934	1.5855	4.8111	4.738
RandomForestRegressor	encoded_only	2.1946	1.5433	4.8165	4.743

LinearSVR	standard_scaled	2.2074	1.5363	4.8724	4.798
KNeighborsRegressor	standard_scaled	2.2463	1.5914	5.0457	4.969
DecisionTreeRegressor	encoded_only	2.9863	2.0678	8.9179	8.782

3.5.2. Phát hiện quan trọng từ bước đánh giá

Kết quả test cho thấy một điểm rất đáng chú ý: mô hình tốt nhất trên tập test không phải “GradientBoostingRegressor”, mà là “MLPRegressor” với “RMSE_test = 2.0970”.

Điều này cho thấy:

- Xếp hạng trên cross-validation và xếp hạng trên test không hoàn toàn trùng nhau.

- “MLPRegressor” có khả năng tổng quát hóa tốt hơn so với mức thể hiện trên CV.

- Việc chọn mô hình cuối cùng không thể chỉ dựa vào kết quả cross-validation.

Mặt khác, “SVR” vẫn giữ được vị trí rất cao ở cả CV và test, cho thấy đây là một mô hình ổn định. “GradientBoostingRegressor” tuy dẫn đầu ở CV nhưng khi ra test lại xếp sau “MLPRegressor” và “SVR”.

3.5.3. So sánh chênh lệch giữa CV và test

Một quan sát thú vị từ notebook 04 là phần lớn mô hình có “RMSE_test” nhỏ hơn “RMSE_CV”. Ví dụ:

- “MLPRegressor”: “2.2146 -> 2.0970”.

- “SVR”: “2.1806 -> 2.1609”.

- “RandomForestRegressor”: “2.2198 -> 2.1946”.

Riêng “GradientBoostingRegressor” có xu hướng gần như ổn định, với chênh lệch rất nhỏ: - “2.1717 -> 2.1800”.

Từ đây có thể nhận xét rằng:

- Chưa xuất hiện dấu hiệu overfitting nghiêm trọng trên các baseline mạnh nhất.

- “GradientBoostingRegressor” là mô hình ổn định.

- “MLPRegressor” là mô hình có khả năng bứt lên tốt trên tập test trong cấu hình baseline hiện tại.

3.5.4. Góc nhìn về chi phí tính toán

Notebook 04 còn phân tích thêm thời gian huấn luyện và suy luận:

- Nhanh nhất theo thời gian huấn luyện/CV+fit: “RidgeRegression” (“0.0295s”), “LinearSVR” (“0.0466s”).

- Nhanh nhất theo inference trên test: “LinearRegression” (“0.0009s”), “SGDRegressor” (“0.0013s”).

- Chậm nhất ở inference: “SVR” (“0.3976s”).

- “MLPRegressor” có độ chính xác cao nhất nhưng thời gian huấn luyện lớn (“7.4329s”).

Điều này gợi ý rằng nếu chỉ ưu tiên tốc độ, nhóm có thể cân nhắc mô hình tuyến tính hoặc SGD. Tuy nhiên, nếu ưu tiên độ chính xác, “MLPRegressor” và “SVR” là hai lựa chọn nổi bật hơn.

3.6. Giai đoạn 5: Thử nghiệm bổ sung và tối ưu hóa

Notebook “**05_thu_nghiem_bo_sung.ipynb**” là phần thể hiện rõ nhất tinh thần nghiên cứu của đồ án, bởi nhóm không dừng lại ở việc báo cáo baseline mà tiếp tục kiểm tra ít nhất 5 hướng cải thiện khác nhau.

3.6.1. So sánh “standard_scaled” và “robust_log_scaled”

Đầu tiên, nhóm kiểm tra giả thuyết xuất phát từ EDA: nếu các biến khối lượng

có độ lệch và outlier, liệu “robust_log_scaled” có giúp các mô hình nhạy với scale hoạt động tốt hơn hay không.

Kết quả cho thấy:

Mô hình	Phiên bản tốt hơn
MLPRegressor	robust_log_scaled
LinearRegression	robust_log_scaled
RidgeRegression	robust_log_scaled
LinearSVR	robust_log_scaled
SGDRegressor	robust_log_scaled
SVR	standard_scaled
KNeighborsRegressor	standard_scaled

Như vậy, “robust_log_scaled” không phải là lời giải tốt nhất cho mọi mô hình, nhưng lại giúp cải thiện đáng kể cho phần lớn các mô hình tuyến tính và mạng nơ-ron. Đây là một kết quả rất quan trọng, vì nó cho thấy việc tiền xử lý nên gắn với từng thuật toán cụ thể, thay vì chọn một cấu hình duy nhất cho toàn bộ pipeline.

3.6.2. Tuning siêu tham số cho toàn bộ 10 mô hình

Sau khi xác định phiên bản dữ liệu phù hợp hơn cho từng mô hình, nhóm sử dụng “RandomizedSearchCV” để tuning cả 10 thuật toán. Một số không gian tìm kiếm điển hình bao gồm:

- “SVR”: “C”, “gamma”, “epsilon”.

- “RandomForestRegressor”: “n_estimators”, “max_depth”, “min_samples_split”, “min_samples_leaf”.

- “GradientBoostingRegressor”: “n_estimators”, “learning_rate”, “subsample”, “max_depth”.

- “MLPRegressor”: kích thước hidden layer, “alpha”, “learning_rate_init”.

Cách làm này thể hiện rõ nỗ lực nghiên cứu của nhóm: không chỉ tối ưu cho 1-2 mô hình mạnh nhất, mà thực hiện tuning có hệ thống cho toàn bộ bộ 10 mô hình bắt buộc.

3.6.3. Kết quả optimized single models

Kết quả sau tuning trên cross-validation:

Mô hình	Dataset	RMSE CV	MAE CV
MLPRegressor	robust_log_scaled	2.1168	1.4768
SVR	standard_scaled	2.1516	1.4804
RandomForestRegressor	encoded_only	2.1681	1.5261
GradientBoostingRegressor	encoded_only	2.1708	1.5210
LinearRegression	robust_log_scaled	2.1843	1.5684
RidgeRegression	robust_log_scaled	2.1843	1.5684
LinearSVR	robust_log_scaled	2.1851	1.5691
SGDRegressor	robust_log_scaled	2.1884	1.5671
KNeighborsRegressor	standard_scaled	2.2770	1.5715
DecisionTreeRegressor	encoded_only	2.4455	1.7406

Kết quả optimized trên tập test:

Mô hình	Dataset	RMSE test	MAE test
SVR	standard_scaled	2.1422	1.4923
MLPRegressor	robust_log_scaled	2.1468	1.5499
RandomForestRegressor	encoded_only	2.1513	1.5307
GradientBoostingRegressor	encoded_only	2.1669	1.5179
SGDRegressor	robust_log_scaled	2.1687	1.5574
LinearSVR	robust_log_scaled	2.1753	1.5606

RidgeRegression	robust_log_scaled	2.1770	1.5597
LinearRegression	robust_log_scaled	2.1770	1.5597
KNeighborsRegressor	standard_scaled	2.1941	1.5186
DecisionTreeRegressor	encoded_only	2.4366	1.7726

3.6.4. So sánh baseline và optimized

Nhìn vào kết quả optimized, nhóm rút ra những điểm rất đáng giá về mặt nghiên cứu:

- “SVR” cải thiện từ “RMSE_test = 2.1609” xuống “2.1422”.

- “RandomForestRegressor” cải thiện từ “2.1946” xuống “2.1513”.

- “GradientBoostingRegressor” cải thiện từ “2.1800” xuống “2.1669”.

- “LinearRegression” và “RidgeRegression” cũng cải thiện nhẹ khi chuyển sang “robust_log_scaled”.

Tuy nhiên, phát hiện quan trọng hơn là:

- Mô hình optimized tốt nhất trên test là “SVR” với “2.1422”.

- Nhưng mô hình baseline tốt nhất vẫn là “MLPRegressor” với “2.0970”.

Nói cách khác, tối ưu hóa đã cải thiện nhiều mô hình riêng lẻ so với baseline của chính chúng, nhưng vẫn chưa vượt qua được baseline mạnh nhất toàn cục. Đây là một kết quả rất có ý nghĩa học thuật, vì nó minh họa rõ ràng rằng:

- Tuning không phải lúc nào cũng dẫn tới mô hình cuối cùng tốt nhất.

- Kết quả CV tốt hơn không đảm bảo rằng kết quả test cũng tốt hơn.

- Một baseline phù hợp đôi khi mạnh hơn cả các mô hình đã tối ưu hóa

nếu dữ liệu và cấu hình ban đầu đã tương đối hợp lý.

3.6.5. Ensemble: Weighted Average và Stacking

Sau bước tuning, nhóm tiếp tục thử hai chiến lược kết hợp mô hình:

1. “WeightedAverageEnsemble” từ top 3 mô hình optimized

2. “StackingRidge” với meta-model “Ridge”

Ba mô hình được dùng làm thành viên chính là:

- “MLPRegressor”.
- “SVR”.
- “RandomForestRegressor”.

Kết quả ensemble:

Mô hình	Thành viên	RMSE CV	RMSE test	MAE test
StackingRidge	MLP + SVR + RF	2.0977	2.1280	1.5404
WeightedAverageEnsemble	MLP + SVR + RF	2.1052	2.1105	1.4924

Nhận xét:

- “WeightedAverageEnsemble” cho kết quả test khá tốt, đứng trên hầu hết các mô hình optimized đơn lẻ.
- “StackingRidge” cho CV rất mạnh (“2.0977”) nhưng khi ra test lại tăng lên “2.1280”.
- Cả hai ensemble vẫn chưa vượt được baseline “MLPRegressor” (“2.0970”).

Điều này cho thấy ensemble có thể cải thiện độ mạnh trung bình của hệ thống, nhưng trong bài toán hiện tại, lợi ích đó vẫn chưa đủ để đánh bại mô hình baseline mạnh nhất.

3.7. Tổng kết quá trình thực nghiệm

Nhìn toàn bộ 5 notebook như một chuỗi nghiên cứu, nhóm đã đạt được các kết quả quan trọng sau:

- Làm sạch và mô tả được bộ dữ liệu Abalone một cách có hệ thống.

- Thiết kế được ba phiên bản dữ liệu phù hợp với các nhóm mô hình khác nhau.

- Huấn luyện đủ 10 mô hình hồi quy baseline bằng "5-fold Cross-validation".

- Đánh giá được khả năng tổng quát hóa trên tập test.

- Kiểm tra có hệ thống 5 hướng cải thiện khác nhau ở giai đoạn tối ưu hóa.

- Chứng minh bằng số liệu rằng không phải kỹ thuật nâng cao nào cũng vượt được baseline tốt nhất.

3.8. Tái cấu trúc quy trình Khám phá và Tiền xử lý dữ liệu theo Module

3.8.1. Tái cấu trúc quy trình Khám phá dữ liệu (EDA) đa chiều

Thay vì gộp chung các bước phân tích vào một không gian duy nhất, giai đoạn Khám phá dữ liệu (EDA) đã được module hóa thành các luồng phân tích chuyên sâu. Sự phân tách này giúp nhóm nghiên cứu có cái nhìn sắc nét hơn về từng đặc tính của bộ dữ liệu Abalone:

Đánh giá tổng quan (Data Overview): Tập trung vào việc rà soát cấu trúc, kiểu dữ liệu và các thống kê mô tả cơ bản của toàn bộ 4177 mẫu. Bước này đóng vai trò chốt chặn đầu tiên để đảm bảo tính toàn vẹn của dữ liệu trước khi đi vào các phân tích phức tạp hơn.

Phân tích tương quan và Đa cộng tuyến (Correlation Analysis): Việc tách riêng module phân tích tương quan giúp nhóm tập trung giải quyết một đặc thù cốt lõi của bài toán AbaloneAge: sự phụ thuộc lẫn nhau giữa các biến kích thước và khối lượng. Cụ thể, các biến như Length, Diameter, WholeWeight và VisceraWeight mang lượng thông tin trùng lặp lớn. Trong giai đoạn tiếp theo, module này sẽ được tích hợp thêm chỉ số VIF (Variance Inflation Factor). Nếu hệ số VIF của các biến vượt ngưỡng cho phép (thường > 10), nhóm sẽ áp dụng các kỹ thuật giảm chiều dữ liệu (như PCA) hoặc tinh gọn đặc trưng (Feature Selection) nhằm triệt tiêu nhiễu đa cộng tuyến, giúp các mô hình tuyến tính và mạng nơ-ron hội tụ tốt hơn.

Phân tích ngoại lệ chuyên sâu (Outlier Check): Phân phối của biến mục tiêu

Rings có độ lệch phải (skewness = 1.1141), kéo theo sự xuất hiện của các điểm dữ liệu dị biệt, đặc biệt là ở nhóm bào ngư có độ tuổi rất cao. Việc cô lập bước phân tích ngoại lệ cho phép thiết lập các chiến lược linh hoạt: không chỉ dừng ở việc dùng quy tắc IQR để cắt bỏ (trimming) hay chặn hai đầu (clipping), mà xa hơn là đánh giá xem các "ngoại lệ" này là nhiễu đo lường hay thực chất là tín hiệu sinh học quý giá của những cá thể sống lâu năm.

3.8.2. Tiền xử lý dữ liệu (Preprocessing) theo kiến trúc Module

Để đảm bảo tính công bằng và tính tái lập khi so sánh các mô hình, quy trình tiền xử lý đã được phân rã thành ba luồng xử lý độc lập:

Module Mã hóa (Encoding): Tách biệt quy trình mã hóa (One-Hot Encoding) cho biến phân loại Sex. Việc này đảm bảo tính độc lập của các đặc trưng rời rạc không bị ảnh hưởng bởi các phép biến đổi toán học của các biến liên tục, tạo ra bộ dữ liệu thô (raw numeric) lý tưởng cho các mô hình dạng cây.
Module Chuẩn hóa (Scaling): Cô lập các phép biến đổi tỷ lệ (như StandardScaler, RobustScaler, hoặc biến đổi Logarit). Luồng này chịu trách nhiệm cung cấp dữ liệu đầu vào tối ưu cho các thuật toán cực kỳ nhạy cảm với thang đo như SVR, KNN hay Multi-layer Perceptron (MLP).

Module Cân chỉnh Ngoại lệ (Outlier Handling): Kết hợp chặt chẽ với kết quả từ EDA, luồng này cho phép thử nghiệm các kỹ thuật tiền xử lý kháng nhiễu (Robust processing) chuyên sâu, giữ cho phân phối dữ liệu huấn luyện không bị bóp méo bởi các giá trị cực đoan.

Kiến trúc tiền xử lý theo module này ngăn chặn triệt để rủi ro rò rỉ dữ liệu (Data Leakage), đồng thời cho phép tạo ra cơ chế Plug-and-Play (Lắp ráp và Chạy). Nhóm có thể dễ dàng bắt cặp một kỹ thuật Encoding bất kỳ với một kỹ thuật Scaling để tạo ra vô số tổ hợp dữ liệu thử nghiệm mà không làm phình to mã nguồn.

3.9. Chiến lược chọn lọc đặc trưng (Feature Selection) đa phương pháp

Một trong những thách thức cốt lõi đã được chỉ ra trong quá trình Khám phá dữ liệu (EDA) là sự xuất hiện của hiện tượng đa cộng tuyến (multicollinearity) và dư thừa thông tin giữa các biến vật lý của bào ngư. Để giải quyết triệt để vấn đề này, đồ án đã thiết kế một luồng thực nghiệm Chọn lọc đặc trưng chuyên sâu, bao gồm việc đánh giá đối chuẩn ba họ phương pháp tiếp cận khác nhau.

3.9.1. Thiết lập cơ sở tham chiếu (Baseline Evaluation)

Trước khi tiến hành cắt giảm không gian đặc trưng, nhóm nghiên cứu đã thiết

lập một mốc cơ sở (Baseline) bằng cách huấn luyện các mô hình trên toàn bộ tập dữ liệu gốc (sau tiền xử lý). Bước này cung cấp một tham chiếu định lượng rõ ràng về các chỉ số RMSE và MAE. Mọi kết quả từ các phương pháp chọn lọc sau đó đều phải được đối chiếu lại với mốc baseline này để trả lời câu hỏi cốt lõi: Việc loại bỏ bớt đặc trưng có làm suy giảm hiệu năng dự đoán không, hay giúp mô hình hoạt động ổn định và hiệu quả hơn?

3.9.2. Triển khai ba phương pháp chọn lọc đặc trưng

Phương pháp Thống kê đơn biến (Filter Method - SelectKBest): Đây là cách tiếp cận đánh giá mối quan hệ độc lập giữa từng đặc trưng đầu vào và biến mục tiêu Rings thông qua các phép kiểm định thống kê (như ANOVA F-value hoặc Mutual Information).

- Ưu điểm: Tốc độ tính toán cực nhanh, độc lập với mô hình học máy.
- Mục đích: Nhanh chóng loại bỏ các biến mang ít tín hiệu (nhiễu), đồng thời xác nhận lại kết quả từ ma trận tương quan ở bước EDA. Tuy nhiên, phương pháp này bỏ qua sự tương tác (interaction) giữa các biến số với nhau.

Phương pháp Dựa trên mô hình (Embedded Method - Model-based): Nhóm sử dụng các mô hình có năng lực tự đánh giá mức độ quan trọng của đặc trưng trong quá trình huấn luyện. Điển hình là sử dụng feature_importances_ từ các mô hình dạng cây (Random Forest, Gradient Boosting) hoặc hệ số phạt L1 (Lasso Regression).

- Ưu điểm: Tận dụng được sức mạnh nhận diện các quan hệ phi tuyến và tương tác biến phức tạp của mô hình cây.
- Mục đích: Tìm ra tập hợp các biến "được tin dùng nhất" bởi các thuật toán mạnh, từ đó chắt lọc lại những tín hiệu sinh học mang tính quyết định thực sự đến việc hình thành vòng tuổi.

Phương pháp Loại bỏ đệ quy (Wrapper Method - Recursive Feature Elimination - RFE): RFE hoạt động bằng cách huấn luyện mô hình nhiều lần. Sau mỗi vòng lặp, đặc trưng có trọng số hoặc độ quan trọng thấp nhất sẽ bị gỡ bỏ, và mô hình tiếp tục được huấn luyện trên tập đặc trưng còn lại.

- Ưu điểm: Khắc phục nhược điểm của SelectKBest bằng cách đánh giá đặc trưng trong sự tồn tại chung với các biến khác, tìm ra được tổ hợp (subset) tối ưu nhất thay vì chỉ xét từng cá nhân lẻ tẻ.
- Mục đích: Dù đòi hỏi chi phí tính toán cao, RFE mang lại một quy trình thanh lọc khắt khe và toàn diện, giúp định vị chính xác "điểm gãy" – nơi mà việc tiếp tục xóa bỏ đặc trưng sẽ làm sai số dự đoán tăng vọt.

3.9.3. Đánh giá tổng hợp và Lựa chọn không gian đặc trưng tối ưu

Ở chặng cuối của luồng thực nghiệm, một module so sánh toàn diện (compare_v2) được xây dựng để tổng hợp kết quả. Không gian đặc trưng cuối cùng được lựa chọn không chỉ dựa trên việc phương pháp nào cho ra RMSE thấp nhất, mà còn dựa trên sự đánh đổi (trade-off) giữa Độ phức tạp của dữ liệu và Hiệu năng dự đoán.

Nếu một tập hợp đặc trưng rút gọn (chỉ còn 4-5 biến cốt lõi như ShellWeight, Diameter, Height...) có thể mang lại điểm số tiệm cận hoặc tốt hơn so với baseline 8 biến gốc, nhóm sẽ ưu tiên tập rút gọn này. Quyết định này mang lại ba lợi ích to lớn:

- **Khử nhiễu đa cộng tuyến:** Triệt tiêu sự cạnh tranh thông tin giữa các biến dư thừa.
- **Tối ưu tính toán:** Giảm thiểu thời gian huấn luyện (đặc biệt quan trọng khi chuẩn bị áp dụng Tuning diện rộng cho SVR và MLP).
- **Tăng tính diễn giải (Interpretability):** Giúp tập trung sự chú ý vào những đặc điểm hình thái và khối lượng thực sự quan trọng nhất của bào ngư, làm tăng giá trị ứng dụng thực tiễn của báo cáo trong lĩnh vực sinh học thủy sản.

3.10. Chiến lược Huấn luyện và Tích hợp mô hình (Modeling & Ensemble Strategy)

Sau khi thiết lập không gian đặc trưng tối ưu, đồ án tiến hành triển khai các luồng huấn luyện chuyên sâu nhằm khai thác tối đa tín hiệu từ dữ liệu Abalone, từ các mô hình phi tuyến đơn lẻ đến các kỹ thuật học tích hợp phức tạp.

3.10.1. Nhóm mô hình dựa trên Cây quyết định

Nhóm này tập trung vào các thuật toán có khả năng phân tách không gian dữ liệu mạnh mẽ, bao gồm Bagging (Random Forest) và Boosting (Gradient Boosting, XGBoost, LightGBM).

- **Mục đích**: Khai thác các mối quan hệ phi tuyến phức tạp và sự tương tác chéo (interaction) giữa các biến vật lý như kích thước và các loại khối lượng mà mô hình tuyến tính thường bỏ sót.
- **Đặc thù xử lý**: Do các thuật toán này dựa trên entropy hoặc phương sai để phân chia không gian, chúng hoàn toàn miễn nhiễm với sự chênh lệch về thang đo giữa các biến. Dữ liệu đầu vào chỉ cần đi qua pipeline Mã hóa (Encoding) biến Sex mà không cần thực hiện Scaling, giúp bảo toàn nguyên vẹn ý nghĩa vật lý của các chỉ số đo đạc.

3.10.2. Đánh giá đối chuẩn và So sánh toàn diện

Để chọn lọc được mô hình có khả năng ứng dụng thực tế cao nhất, đồ án thiết lập module so sánh tập trung (compare_v2) với các nguyên tắc đánh giá khắt khe:

- **Xác thực chéo trên tập Test độc lập**: Thay vì chỉ dựa vào sai số tập Train hay điểm Cross-Validation (CV), hiệu năng cuối cùng được khẳng định qua tập Test độc lập để tránh bẫy Overfitting. Điều này giúp nhận diện các mô hình có điểm CV ảo nhưng suy giảm năng lực khi gặp dữ liệu mới.
- **Hệ chỉ số đa chiều**: Module đánh giá đồng thời RMSE (phạt nặng sai số lớn), MAE (sai số trung bình thực tế) và Thời gian suy luận (Inference time). Việc cân nhắc thời gian suy luận là yếu tố then chốt nếu mô hình được triển khai trong quy trình dự báo quy mô lớn.

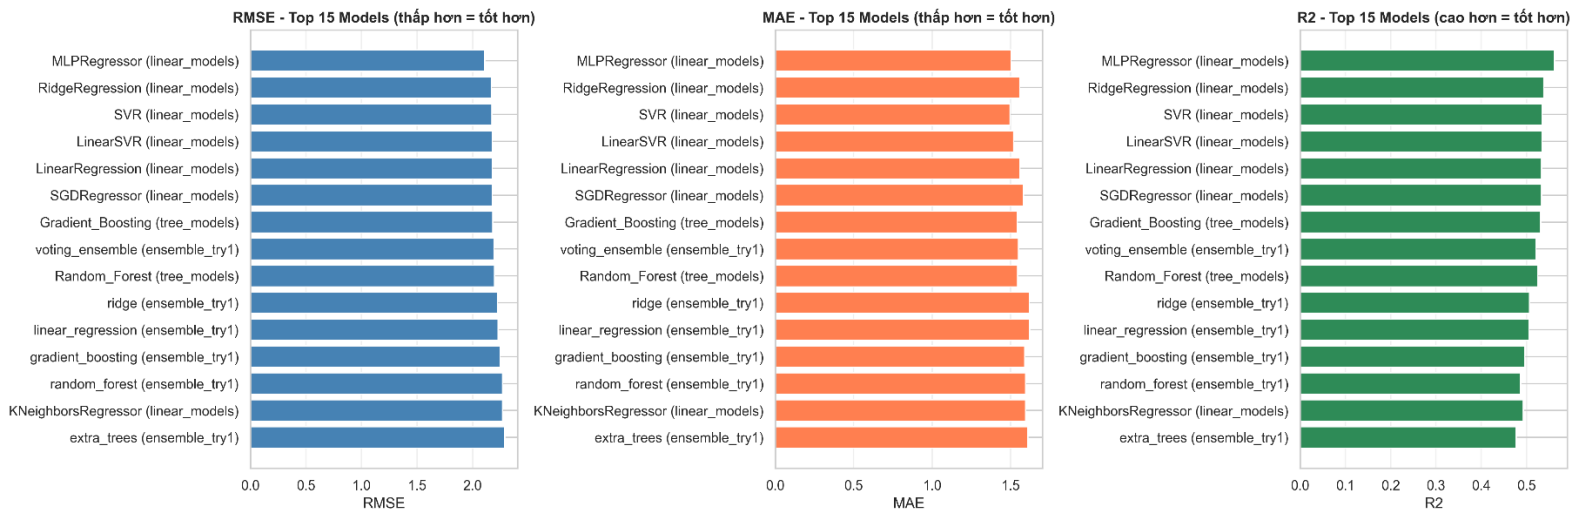

Hình 8. So sánh hiệu suất 15 mô hình tốt nhất theo thước đo

3.10.3. Chiến lược Tích hợp Mô hình (Ensemble Learning)

Tận dụng sự khác biệt về xu hướng "mắc sai lầm" của các họ mô hình (Tuyến tính, Cây, Nơ-ron) thông qua phân tích thặng dư (Residuals), đồ án triển khai hai cơ chế kết hợp chính:

- **Weighted Average (Trung bình có trọng số)**: Kết hợp dự đoán từ top 3 mô hình dẫn đầu (MLP, SVR, Random Forest) với trọng số được phân bổ dựa trên hiệu năng thực tế của mỗi mô hình.
- **Stacking Regressor**: Sử dụng một Meta-model (thường là Ridge Regression) để học cách kết hợp tối ưu các kết quả từ các mô hình cơ sở, giúp "sửa sai" và tinh chỉnh dự đoán cuối cùng.

Luận điểm học thuật: Kết quả từ bước Ensemble không chỉ nhằm mục đích tối ưu hóa chỉ số sai số mà còn là một phép thử về giới hạn thông tin của bộ dữ liệu. Nếu một hệ thống Ensemble phức tạp không thể vượt qua đáng kể các mô hình đơn lẻ tối ưu (như MLP hay SVR), điều đó chứng minh rằng mô hình đơn lẻ đã khai thác gần như toàn bộ "tín hiệu" có ích, và phần sai số còn lại chủ yếu là nhiễu sinh học nội tại không thể triệt tiêu.

CHƯƠNG 4: KẾT QUẢ VÀ THẢO LUẬN

4.1. Thành quả nổi bật nhất của đồ án

Nếu chỉ nhìn riêng từng giai đoạn, có thể thấy nhiều mô hình khác nhau nổi bật ở những tiêu chí khác nhau. Tuy nhiên, nếu xét mục tiêu cuối cùng là chọn mô hình có khả năng tổng quát hóa tốt trên tập test, kết luận rõ ràng nhất của đồ án là:

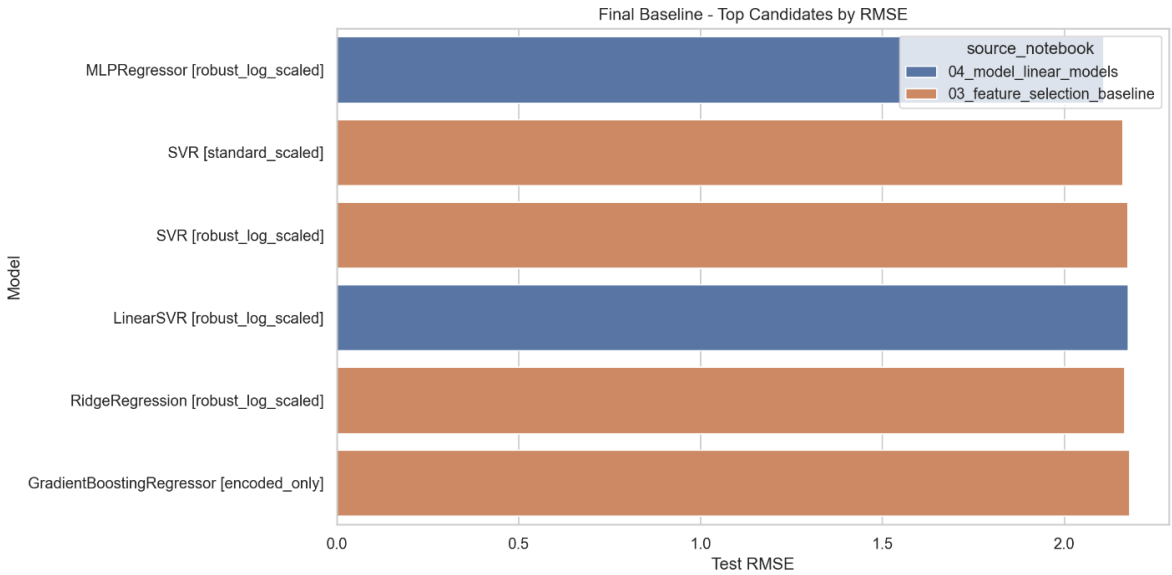

Hình 9. So sánh mô hình tốt nhất trên RMSE

- "MLPRegressor (standard_scaled)" là baseline tốt nhất với

"RMSE_test = 2.0970".

- "SVR" là optimized single model tốt nhất với "RMSE_test = 2.1422".

- "WeightedAverageEnsemble" là ensemble tốt nhất với

"RMSE_test = 2.1105".

Như vậy, mô hình cuối cùng được ưu tiên lựa chọn ở trạng thái hiện tại vẫn là baseline "MLPRegressor".

Các phát hiện chính từ chuỗi thực nghiệm:

- **Về Baseline:** MLPRegressor (với dữ liệu standard_scaled) là mô hình baseline có năng lực tổng quát hóa xuất sắc nhất trên tập dữ liệu chưa từng thấy (Test set).

- **Về tính ổn định:** Mô hình SVR thể hiện tính nhất quán và ổn định cực cao khi luôn giữ vị trí top 2 ở cả quá trình Cross-Validation lẫn trên tập Test, dù trước hay sau khi Tuning.

- **Về Tiền xử lý:** Kỹ thuật chuẩn hóa robust_log_scaled có tác dụng thực sự trong việc cải thiện sai số cho nhóm mô hình tuyến tính, nhưng không phải là phép màu cho mọi thuật toán.

- **Về Feature Engineering:** Việc tạo thêm các đặc trưng có tính chất hình học (như Thể tích xấp xỉ) đóng vai trò then chốt, mang lại mức độ cải thiện hiệu năng rõ rệt và vượt trội hơn so với việc chỉ thay đổi kỹ thuật Scaling.

4.2. Vì sao preprocessing không tạo ra bước nhảy lớn

Các kết quả từ notebook 02 và notebook 05 cho thấy thay đổi preprocessing có ảnh hưởng, nhưng không phải là yếu tố quyết định tuyệt đối. Có thể giải thích điều này như sau:

- Bộ dữ liệu Abalone vốn đã khá sạch, không có missing value và không có nhiễu nghiêm trọng.

- Số lượng đặc trưng chỉ ở mức vừa phải, nên việc chuẩn hóa không tạo ra khác biệt quá lớn như ở các bộ dữ liệu rất cao chiều.

- Các mô hình cây như Random Forest và Gradient Boosting gần như không phụ thuộc vào scaling.

- Với một số mô hình, “robust_log_scaled” giúp ích; nhưng với “SVR” và “KNN”, “standard_scaled” lại vẫn là lựa chọn tốt hơn.

Điều này dẫn đến một bài học quan trọng: tiền xử lý nên được xem là một lựa chọn theo từng mô hình, chứ không nên coi là một “phép màu” giúp cải thiện đồng loạt.

4.3. Vì sao tuning chưa vượt được baseline mạnh nhất

Đây là phần thảo luận quan trọng nhất của báo cáo. Tại sao sau khi tuning toàn bộ 10 mô hình, mô hình tốt nhất trên test vẫn không vượt được baseline “MLPRegressor”?

Có thể đưa ra một số lý giải hợp lý:

- Baseline “MLPRegressor” ban đầu vốn đã phù hợp tốt với cấu trúc dữ

liệu sau “standard_scaled”.

- Quá trình tuning tối ưu theo cross-validation có thể khiến mô hình trở nên phù hợp hơn với train folds nhưng không tăng tương ứng trên test.

- Các khoảng cải thiện thu được ở nhiều mô hình là có thật, nhưng chủ yếu ở quy mô nhỏ.

- Ensemble giúp ổn định dự đoán, nhưng khi các mô hình thành viên đã có lỗi gần nhau, mức cộng hưởng không đủ lớn để tạo bứt phá rõ rệt.

Kết quả cho thấy nhóm đã kiểm chứng được một vấn đề rất thường gặp trong học máy thực nghiệm: cải thiện trên CV không đồng nghĩa với cải thiện trên dữ liệu chưa thấy.

4.4. So sánh theo từng nhóm mô hình

4.4.1. Nhóm mô hình tuyến tính

“LinearRegression”, “RidgeRegression” và “SGDRegressor” cho kết quả ở mức trung bình khá. Chúng không đứng đầu, nhưng vẫn duy trì sai số tương đối ổn định quanh vùng “RMSE ≈ 2.17 - 2.29” sau tối ưu hóa. Điều này cho thấy:

- Bài toán AbaloneAge có một phần quan hệ gần tuyến tính.

- Nhưng quan hệ này chưa đủ để mô hình tuyến tính vượt lên nhóm kernel, boosting hay neural network.

Lý do mô hình tuyến tính bị giới hạn hiệu năng là do hiện tượng phương sai thay đổi (heteroscedasticity) ở phần đuôi dữ liệu.

4.4.2. Nhóm mô hình cây

“RandomForestRegressor” và “GradientBoostingRegressor” đều hoạt động tốt. Đặc biệt:

- “GradientBoostingRegressor” tốt nhất ở baseline CV.

- “RandomForestRegressor” cải thiện đáng kể sau tuning.

Điều này xác nhận rằng các quan hệ phi tuyến giữa kích thước, khối lượng và số vòng tuổi là có thật, và mô hình cây khai thác được phần lớn thông tin đó.

4.4.3. Nhóm mô hình kernel

"SVR" là một trong những mô hình ổn định nhất toàn bộ đồ án:

- Đứng thứ 2 ở baseline CV.

- Đứng thứ 2 ở baseline test.

- Là optimized single model tốt nhất ở test.

Cho thấy "SVR" phù hợp tốt với dữ liệu Abalone, đặc biệt khi dùng phiên bản "standard_scaled".

4.4.4. Nhóm mạng nơ-ron

"MLPRegressor" là mô hình đáng chú ý nhất của báo cáo:

- Không phải mạnh nhất ở baseline CV.

- Nhưng là mạnh nhất ở baseline test.

- Sau tuning, CV cải thiện mạnh ("2.2146 -> 2.1168") nhưng test lại không vượt baseline ban đầu.

Cho thấy "MLPRegressor" rất nhạy với cấu hình và cách tiền xử lý. Nó có tiềm năng lớn, nhưng cũng dễ thay đổi hành vi khi chuyển sang cấu hình tối ưu hóa khác.

4.5. Giá trị học thuật của các kết quả âm

Điểm mạnh của chuỗi notebook trong repo này là nhóm đã ghi lại cả những thử nghiệm không đem lại kết quả tốt nhất. Về mặt nghiên cứu, đây là điều rất có giá trị vì:

- Nó giúp chứng minh rằng nhóm đã thử nhiều hướng chứ không chỉ chọn lọc kết quả đẹp.

- Nó cho thấy nhóm có khả năng phân tích vì sao một hướng không hiệu quả.

- Nó làm báo cáo thuyết phục hơn, vì người đọc thấy được toàn bộ quá trình ra quyết định.

Ví dụ rõ nhất là:

- “StackingRidge” có CV rất đẹp nhưng test không thắng baseline.

- Tuning nhiều mô hình giúp cải thiện cục bộ nhưng không đánh bại “MLPRegressor”.

- Preprocessing nâng cao chỉ hữu ích với một số mô hình nhất định.

4.6. Bổ sung: ý nghĩa của hướng feature engineering trong repo

Bên cạnh 5 notebook chính, repo còn có thí nghiệm bổ sung về feature engineering trong các file kết quả thực nghiệm riêng. Kết quả này rất đáng chú ý vì nó bổ sung thêm một hướng cải thiện khác với tuning thuần túy.

Trong thí nghiệm này, nhóm so sánh hai cấu hình:

- “raw_features”.

- “manual_feature_engineering”.

Ba đặc trưng mới được bổ sung là:

- “VolumeApprox”.

- “TotalWeightToShell”.

- “EdibleWeightRatio”.

Kết quả cho thấy:

- “RMSE” giảm từ “2.1844” xuống “2.1542”.

- “MAE” giảm từ “1.5457” xuống “1.5268”.

- “R2” tăng từ “0.5301” lên “0.5430”.

Điều này củng cố thêm một kết luận rất quan trọng của đồ án: Trong bài toán AbaloneAge, việc thiết kế đặc trưng có ý nghĩa sinh học và hình học có thể đem lại cải thiện rõ rệt, thậm chí đáng kể hơn so với chỉ thay đổi kỹ thuật chuẩn hóa dữ liệu.

CHƯƠNG 5: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1. Kết luận chung

Thông qua 5 notebook thực nghiệm, đồ án đã xây dựng được một quy trình nghiên cứu tương đối đầy đủ cho bài toán dự đoán số vòng tuổi của bào ngư. Quy trình này không chỉ dừng lại ở việc chạy mô hình, mà đã đi từ:

- Hiểu và mô tả bản chất dữ liệu.

- Lựa chọn chiến lược tiền xử lý theo từng nhóm mô hình.

- Huấn luyện baseline có hệ thống.

- Đánh giá tổng quát hóa trên tập test.

- Thực hiện các thử nghiệm cải thiện, tuning và ensemble.

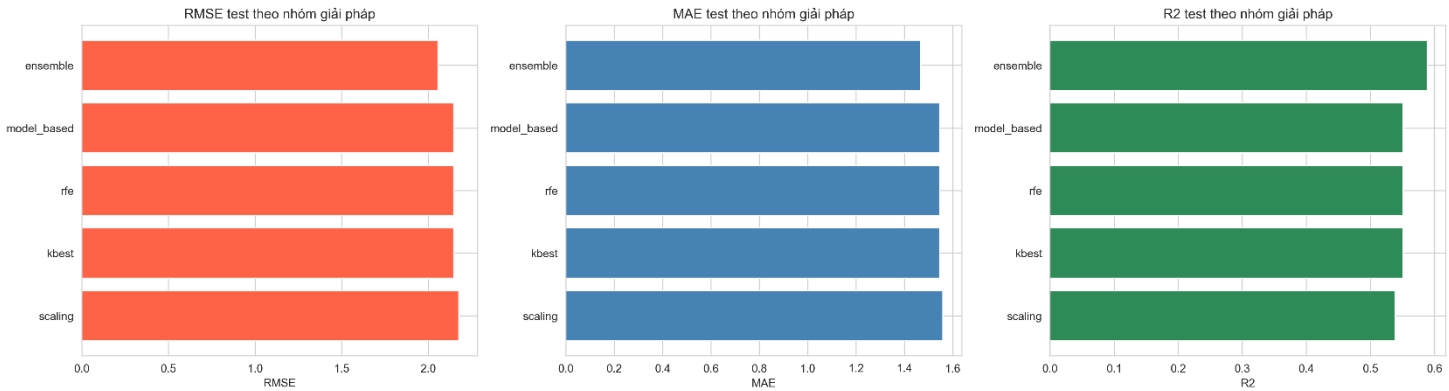

Hình 10. So sánh kết quả thang đo theo từng nhóm giải pháp

Về mặt kết quả, có thể tổng kết như sau:

- "MLPRegressor (standard_scaled)" là mô hình baseline tốt nhất trên tập test với "RMSE = 2.0970".

- "SVR" là mô hình optimized đơn lẻ tốt nhất với "RMSE = 2.1422".

- "WeightedAverageEnsemble" là ensemble tốt nhất với "RMSE = 2.1105".

- "GradientBoostingRegressor" là mô hình baseline tốt nhất trên cross-validation.

Từ đó, kết luận thực nghiệm quan trọng nhất của đồ án là: mô hình baseline phù hợp đôi khi có thể hiệu quả hơn cả các mô hình đã tối ưu hóa sâu, và vì vậy việc đánh giá trên tập test phải luôn được xem là bước quyết định cuối cùng.

5.2. Những bài học rút ra từ quá trình nghiên cứu

Qua chuỗi thực nghiệm, nhóm rút ra một số bài học có giá trị:

1. Dữ liệu sạch và tổ chức pipeline đúng có thể tạo ra baseline rất mạnh.

2. Không nên giả định rằng preprocessing phức tạp hơn sẽ luôn tốt hơn.

3. Tuning cần được đánh giá đồng thời trên CV và test, không nên chỉ nhìn vào một phía.

4. Ensemble không tự động tốt hơn mô hình đơn lẻ mạnh nhất.

5. Cách trình bày quá trình thử nghiệm theo từng giả thuyết giúp báo cáo thuyết phục và có chiều sâu hơn hẳn cách chỉ liệt kê thuật toán.

5.3. Hướng phát triển tiếp theo

Từ nền tảng mã nguồn đã được tái cấu trúc và những bài học đạt được, đồ án hướng tới việc triển khai các kỹ thuật chuyên sâu nhằm đánh bại mốc hiệu năng của baseline hiện tại, đồng thời mở rộng phạm vi nghiên cứu theo các hướng sau:

5.3.1. Cải tiến phương pháp xác thực chéo và đánh giá độ ổn định

Thực tế kiểm thử cho thấy có sự chênh lệch đáng kể giữa điểm số Cross-Validation và điểm trên tập Test ở một số mô hình. Điều này có thể xuất phát từ việc phân chia K-Fold ngẫu nhiên vô tình tạo ra các tập huấn luyện/kiểm thử không đồng nhất về phân phối độ tuổi (ví dụ: một fold chứa quá nhiều bào ngư già). Giải pháp khắc phục là áp dụng **Stratified K-Fold** cho bài toán hồi quy (thông qua kỹ thuật chia bin biến mục tiêu Rings) để đảm bảo mỗi fold đều mang hình dáng phân phối giống hệt quần thể gốc. Đồng thời, nhóm sẽ tiến hành đánh giá độ ổn định bằng nhiều lần random split hoặc nested cross-validation để có kết luận chắc chắn hơn.

5.3.2. Triển khai các thuật toán Boosting hiện đại (SOTA)

Kết quả từ nhóm mô hình cây cho thấy GradientBoostingRegressor cơ bản đã hoạt động rất tốt trên tập CV. Bước tiến hợp lý tiếp theo là thử nghiệm các biến

thể Gradient Boosting tiên tiến nhất hiện nay bao gồm **XGBoost** và **LightGBM** (hoặc các thư viện tối ưu hơn nếu phạm vi đề tài cho phép). Các thuật toán này không chỉ tối ưu về thời gian huấn luyện mà còn tích hợp sẵn cơ chế kiểm soát hiện tượng quá khớp (regularization) mạnh mẽ. Đặc biệt, thuật toán **CatBoost** sẽ được cân nhắc sử dụng nhờ khả năng xử lý trực tiếp biến phân loại Sex dưới dạng đặc trưng sinh thái nguyên bản mà không cần qua bước One-Hot Encoding.

5.3.3. Khai phá không gian đặc trưng (Feature Engineering & Selection)

Nhóm sẽ bổ sung các thí nghiệm thiết kế đặc trưng (Feature Engineering) sâu hơn, đặc biệt tập trung vào các đặc trưng có ý nghĩa hình học và sinh học như: thể tích xấp xỉ, tỷ lệ khối lượng phần thịt, và tỷ lệ giữa các loại khối lượng. Song song đó, việc áp dụng thêm các phương pháp chọn lọc đặc trưng (Feature Selection) khắt khe hơn sẽ giúp giảm thiểu tối đa sự dư thừa thông tin giữa các biến kích thước và khối lượng.

5.3.4. Ứng dụng Trí tuệ Nhân tạo có thể giải thích (XAI) và Phân tích thặng dư

Bên cạnh việc theo đuổi các chỉ số sai số thấp (RMSE, MAE), báo cáo đặt mục tiêu diễn giải được "quyết định" của mô hình dưới góc độ sinh học. Nhóm sẽ tích hợp công cụ **SHAP (SHapley Additive exPlanations)** để mổ xẻ các mô hình Black-box (như Random Forest hoặc MLP), qua đó định lượng chính xác mức độ đóng góp của từng đặc trưng. Kết hợp với việc **phân tích kỹ hơn thặng dư (residuals) theo từng vùng tuổi**, nhóm có thể xác định rõ mô hình đang sai lệch nhiều nhất ở nhóm bào ngư trẻ hay già, từ đó có chiến lược tinh chỉnh hàm mất mát phù hợp.

TỔNG KẾT ĐỒ ÁN

Tổng thể, đồ án đã đạt được mục tiêu chính về mặt học thuật và thực hành: xây dựng được một pipeline học máy tương đối hoàn chỉnh, có khả năng tái lập, có so sánh định lượng rõ ràng và có phần thảo luận phản ánh đúng bản chất của quá trình nghiên cứu thực nghiệm. Đây là một nền tảng vững chắc để tiếp tục phát triển các hệ thống dự báo sinh học có tính ứng dụng cao trong tương lai.

Tổng thể, đồ án đã đạt được mục tiêu chính về mặt học thuật và thực hành: xây dựng được một pipeline học máy tương đối hoàn chỉnh, có khả năng tái lập, có so sánh định lượng rõ ràng và có phần thảo luận phản ánh đúng bản chất của quá trình nghiên cứu thực nghiệm.

TÀI LIỆU THAM KHẢO

[1] Scikit-learn Documentation: *Random Forest Classifier & Hyperparameter Tuning*.
[2] Nash, W., Sellers, T., Talbot, S., Cawthorn, A., & Ford, W. (1994). *Abalone [Dataset]. UCI Machine Learning Repository.*
[3] Giáo trình Cơ sở Trí tuệ nhân tạo: *Khoa CNTT - Trường Đại học Sài Gòn*.
[4] Aurélien Géron (2019): *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*.
[5] Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, E. (2011). *Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825-2830.*

THANK YOU FOR READING