BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC SÀI GÒN
KHOA CÔNG NGHỆ THÔNG TIN
--------*--------**

BÁO CÁO TUẦN 7
MÔN: CƠ SỞ TRÍ TUỆ NHÂN TẠO

Giảng viên hướng dẫn: **TS. Đỗ Như Tài**

Nhóm sinh viên thực hiện:

Cao Nguyễn Yên Hòa	3124410101
Trần Nguyễn Đăng Khoa	3124560042
Lưu Gia Bảo	3124410016
Lâm Hán Đạt	3124410055
Hồ Trung Tín	3124410355

NHẬN XÉT CỦA GIẢNG VIÊN

.....
.....
.....
.....
.....
.....
.....
.....
.....
.....

MỤC LỤC

CHƯƠNG 1: MÔ TẢ VỀ ĐỒ ÁN 6
1.1. Bối cảnh 6
1.2. Hướng giải quyết 6
1.3. Mục đích khi chọn phương án 7
CHƯƠNG 2: PHƯƠNG PHÁP ĐỀ XUẤT 8
2.1. Phân tích và khám phá dữ liệu 8
2.2. Tiền xử lý dữ liệu 12
2.3. Huấn luyện mô hình 15
2.4. Đánh giá mô hình 16
2.5. Thử nghiệm bổ sung 17
Kỹ nghệ đặc trưng nâng cao (Advanced Feature Engineering) 17
CHƯƠNG 3: KẾT QUẢ VÀ ĐÁNH GIÁ 18
3.1 Kết quả thực nghiệm 18
3.2 Phân tích và đánh giá 18
3.2.1 Phân tích ma trận nhầm lẫn 18
3.2.2 Đánh giá Tầm quan trọng của đặc trưng 19
CHƯƠNG 4: HƯỚNG CẢI TIẾN MÔ HÌNH 20
4.1 Xử lý mất cân bằng dữ liệu 20
4.2 Thử nghiệm các mô hình Boosting 20
4.3 Kỹ thuật đặc trưng chuyên sâu 20
4.4 Mở rộng kích thước mẫu 20
TÀI LIỆU THAM KHẢO 21

DANH MỤC HÌNH

Hình 1. Quy trình thử nghiệm tịnh tiến 6
Hình 2. Bảng dữ liệu đầu vào 8
Hình 3. Bảng thống kê mô tả 9
Hình 4. Biểu đồ phân tích phân phối của các đặc trưng 9
Hình 5. Ma trận tương quan giữa các đặc trưng 10
Hình 6. Biểu đồ hợp phân tích các giá trị ngoại lai 11
Hình 7. Biểu đồ phân bố số lượng mẫu giữa nhóm không bị tiểu đường và nhóm bị tiểu đường 12
Hình 8. Biểu đồ thống kê số lượng giá trị thiếu trên từng đặc trưng 13
Hình 9. Biểu đồ phân tích đặc trưng để xác định các biến có khả năng phân loại cao 14
Hình 10. Ma trận nhầm lẫn đánh giá hiệu suất của mô hình Random Forest 18

PHÂN CÔNG

1	Cao Nguyễn Yên Hòa	- Lập kế hoạch dự án - Tổng hợp báo cáo tổng thể. - Bản kế hoạch. - File báo cáo cuối (.docx). - Thiết kế Slide thuyết trình.
2	Trần Nguyễn Đăng Khoa	- Xử lý giá trị thiếu (số 0 lỗi). - Xử lý giá trị ngoại lai (Outliers). - Chuẩn hóa dữ liệu (Scaling). - File dữ liệu sạch. - Code tiền xử lý.
3	Lưu Gia Bảo	- Slide báo cáo. - Trực quan hóa (EDA): Histogram, Heatmap, Boxplot. - Phân tích ý nghĩa các chỉ số y tế. - Hình ảnh biểu đồ. - Bản nhận xét Insights.
4	Lâm Hán Đạt	- Chia tập Train/Test. - Huấn luyện mô hình Random Forest. - Tinh chỉnh tham số (Tuning). - Model huấn luyện. - Code chạy mô hình.
5	Hồ Trung Tín	- Vẽ Ma trận nhầm lẫn (Confusion Matrix). - Tính chỉ số: Accuracy, Recall, Precision. - Đánh giá độ tin cậy mô hình. - Bảng chỉ số đánh giá. - Biểu đồ hiệu suất.

CHƯƠNG 1: MÔ TẢ VỀ ĐỒ ÁN

1.1. Bối cảnh

Trong y học truyền thống, việc xác định một người có bị tiểu đường hay không dựa trên các "tiêu chuẩn vàng" nhưng đi kèm nhiều bất tiện:

- **Xâm lấn (Invasive):** Bệnh nhân phải lấy máu (thử đường huyết lúc đói hoặc xét nghiệm HbA1c).
- **Độ trễ thời gian:** Cần nhịn ăn từ 8–12 tiếng trước khi xét nghiệm. Kết quả không có ngay lập tức mà phải đợi phòng Lab xử lý.
- **Tính thời điểm:** Chỉ số đường huyết có thể thay đổi thất thường theo tâm lý hoặc bữa ăn gần nhất, dẫn đến sai số nếu không theo dõi dài hạn.

1.2. Hướng giải quyết

Quy trình giải quyết bài toán được thực hiện theo phương pháp thử nghiệm tịnh tiến (Incremental Experimentation).

Hình 1. Quy trình thử nghiệm tịnh tiến

Lộ trình thực hiện :

Các đặc trưng quan trọng: Glucose, BMI, Huyết áp, Insulin, Độ tuổi (Age).

Thiết lập nền tảng (Baseline): Xây dựng một mô hình đơn giản nhất (Logistic Regression) với các bước xử lý dữ liệu cơ bản như điền giá trị thiếu bằng Median để làm cột mốc so sánh.

Chuẩn hóa và Tối ưu hóa dữ liệu:

- Thực hiện Scaling (StandardScaler) để đưa các đặc trưng về cùng một thang đo.
- Xử lý nhiễu bằng cách loại bỏ hoặc biến đổi các giá trị ngoại lai (Outliers) thông qua Clipping hoặc Log transform.

Kỹ nghệ đặc trưng (Feature Engineering): Tạo ra các biến tương tác mới như BMI \BMI_Age hoặc Glucose \times BMI để khai thác mối quan hệ phi tuyến tính giữa các thuộc tính.

Lựa chọn và Tinh chỉnh mô hình:

- Thử nghiệm đa dạng các thuật toán: Logistic Regression, SVM, KNN, Random Forest.
- Sử dụng **RandomizedSearchCV** để dò tìm bộ tham số tối ưu (Hyperparameters) cho các mô hình tiềm năng nhất.

Đóng gói (Final Model): Tổng hợp các bước tiền xử lý và tham số tốt nhất để huấn luyện mô hình cuối cùng trên toàn bộ tập dữ liệu, sau đó lưu trữ (Save model) để thực tế hóa ứng dụng

1.3. Mục đích khi chọn phương án

Việc lựa chọn hướng giải quyết theo từng giai đoạn riêng biệt nhằm đạt được mục đích:

- **Kiểm soát biến số chặt chẽ:** Bằng cách chỉ thay đổi một yếu tố duy nhất trong mỗi notebook (ví dụ: chỉ thêm Scaling hoặc chỉ thêm Feature Engineering), chúng ta có thể đánh giá chính xác mức độ đóng góp của từng kỹ thuật vào hiệu năng chung của mô hình.
- **Đảm bảo tính khách quan (Tránh Data Leakage):** Việc phân chia tập Train/Test ngay từ đầu và thực hiện các bước như tính Median hay Scaling dựa trên tập Train giúp đảm bảo mô hình không "biết trước" thông tin từ tập Test, giúp kết quả đánh giá thực tế và đáng tin cậy hơn.
- **Tối ưu hóa tài nguyên và thời gian:** Thay vì Tuning Hyperparameters cho tất cả các mô hình, chúng ta chỉ thực hiện bước này ở giai đoạn 6 sau khi đã xác định được các mô hình có triển vọng nhất ở giai đoạn 5, giúp tiết kiệm chi phí tính toán.
- **Khả năng tái sử dụng và mở rộng:** Cách tiếp cận theo module (từng notebook) giúp dễ dàng quay lại điều chỉnh một bước cụ thể nếu phát hiện sai sót mà không ảnh hưởng đến toàn bộ cấu trúc dự án.
- **Xác định mô hình phù hợp nhất với dữ liệu:** Thông qua việc so sánh giữa các thuật toán khác nhau (Linear vs Non-linear), dự án sẽ tìm ra "lời giải" tối ưu nhất cho đặc thù riêng của bộ dữ liệu hiện tại

CHƯƠNG 2: PHƯƠNG PHÁP ĐỀ XUẤT

2.1. Phân tích và khám phá dữ liệu

Giai đoạn này tập trung vào việc hiểu rõ cấu trúc và chất lượng dữ liệu đầu vào, tạo tiền đề vững chắc cho các bước huấn luyện mô hình phía sau.

	Pregnancies	Glucose	BloodPressure	SkinThickness	Insulin	BMI	DiabetesPedigreeFunction	Age	Outcome
0	6	148	72	35	0	33.6	0.627	50	1
1	1	85	66	29	0	26.6	0.351	31	0
2	8	183	64	0	0	23.3	0.672	32	1
3	1	89	66	23	94	28.1	0.167	21	0
4	0	137	40	35	168	43.1	2.288	33	1
5	5	116	74	0	0	25.6	0.201	30	0
6	3	78	50	32	88	31.0	0.248	26	1
7	10	115	0	0	0	35.3	0.134	29	0
8	2	197	70	45	543	30.5	0.158	53	1
9	8	125	96	0	0	0.0	0.232	54	1

Hình 2. Bảng dữ liệu đầu vào

Hướng giải quyết sẽ là chuyển các giá trị 0 này thành NaN và xử lý điền thiếu bằng phương pháp Median để không làm rò rỉ thông tin từ tập Test

Cột Insulin & Glucose: Chỉ ra dòng số 0, 1, 2, 5 có **Insulin = 0**. Điều này khớp với kế hoạch: *"Xác định lỗi dữ liệu cần xử lý tại các cột quan trọng"*.

Cột BMI: Chỉ ra dòng số 9 có **BMI = 0.0**. Đây là dữ liệu không hợp lệ trong thực tế y khoa và cần được thay thế bằng **Median** như ta đã nêu trong Giai đoạn 1.

Cột BloodPressure (Huyết áp): Dòng số 7 có giá trị bằng 0, minh chứng cho việc cần rà soát tính hợp lệ trước khi huấn luyện

Khởi tạo và Nạp dữ liệu

- Sử dụng thư viện **pandas** để quản lý cấu trúc dữ liệu bảng, **numpy** cho các tính toán số học và **sklearn** để thực hiện phân chia dữ liệu.
- Dữ liệu thô từ các định dạng phổ biến như **.csv** hoặc **.xlsx** sẽ được nạp vào đối tượng DataFrame để dễ dàng thao tác.

Kiểm tra tính hợp lệ và Làm sạch dữ liệu

- **Rà soát giá trị lỗi**: Thực hiện kiểm tra các giá trị bằng 0 tại các cột chỉ số sinh học quan trọng như Glucose, BMI, và Huyết áp. Trong bối cảnh y tế, các giá trị này bằng 0 thường là lỗi nhập liệu hoặc thiếu thông tin thay vì là giá trị thực tế.
- **Xử lý giá trị thiếu**: Các giá trị 0 không hợp lệ sẽ được chuyển đổi sang định dạng **NaN** (Not a Number). Sau đó, phương pháp **Median** (giá trị trung vị) được áp dụng để điền đầy các khoảng trống này nhằm duy trì kích thước mẫu mà không làm lệch phân phối dữ liệu quá lớn

	Pregnancies	Glucose	BloodPressure	SkinThickness	Insulin	BMI	DiabetesPedigreeFunction	Age	Outcome
count	768.000000	768.000000	768.000000	768.000000	768.000000	768.000000	768.000000	768.000000	768.000000
mean	3.845052	120.894531	69.105469	20.536458	79.799479	31.992578	0.471876	33.240885	0.348958
std	3.369578	31.972618	19.355807	15.952218	115.244002	7.884160	0.331329	11.760232	0.476951
min	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.078000	21.000000	0.000000
25%	1.000000	99.000000	62.000000	0.000000	0.000000	27.300000	0.243750	24.000000	0.000000
50%	3.000000	117.000000	72.000000	23.000000	30.500000	32.000000	0.372500	29.000000	0.000000
75%	6.000000	140.250000	80.000000	32.000000	127.250000	36.600000	0.626250	41.000000	1.000000
max	17.000000	199.000000	122.000000	99.000000	846.000000	67.100000	2.420000	81.000000	1.000000

Hình 3. Bảng thống kê mô tả

Sau khi quan sát dữ liệu thô và tiến hành thống kê mô tả để đánh giá tổng thể. Kết quả cho thấy giá trị nhỏ nhất (min) của nhiều chỉ số sinh học quan trọng bằng 0, gây sai lệch cho các tính toán toán học. Đồng thời, độ lệch chuẩn (std) và khoảng cách giữa các giá trị cho thấy sự cần thiết của việc chuẩn hóa (Scaling) và xử lý ngoại lai (Outlier) trong các bước tiếp theo.

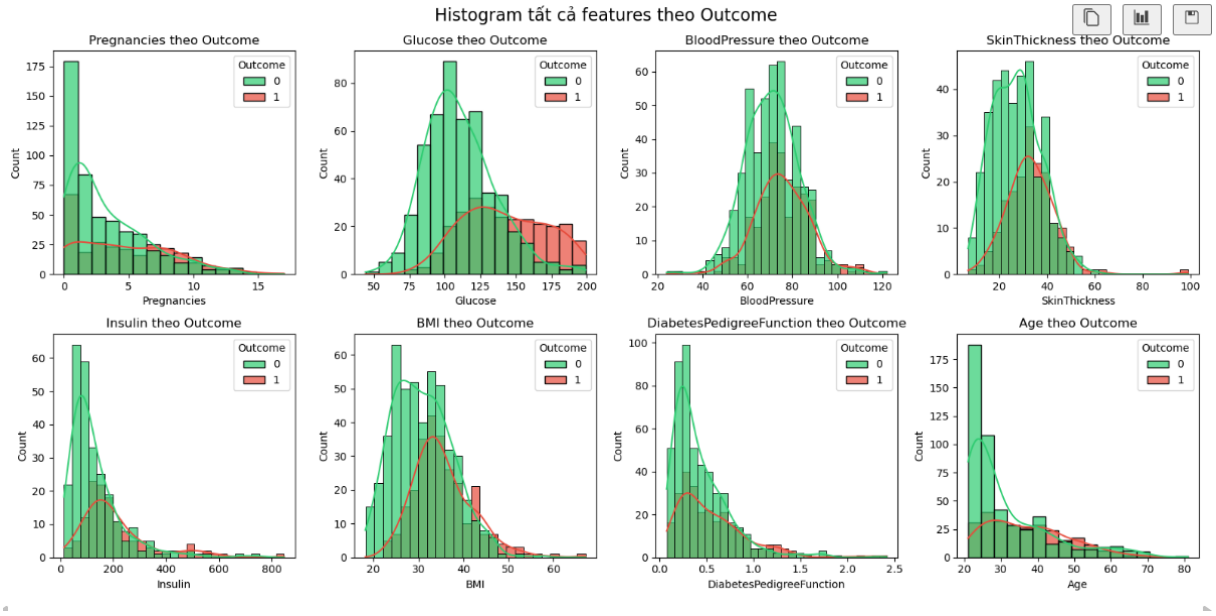

Hình 4. Biểu đồ phân tích phân phối của các đặc trưng

Quan sát cho thấy nhiều biến số có phân phối lệch đáng kể, tiêu biểu là **Insulin** và **Age**, đặt ra yêu cầu về việc xử lý ngoại lai và chuẩn hóa dữ liệu. Sự khác biệt về phân phối của **Glucose** giữa hai nhóm **Outcome** khẳng định giá trị dự báo cao của biến này, đồng thời việc các phân phối khác bị chồng lấn là cơ sở để nhóm triển khai Kỹ nghệ đặc trưng (Feature Engineering) nhằm tối ưu hóa khả năng phân loại của mô hình cuối cùng."

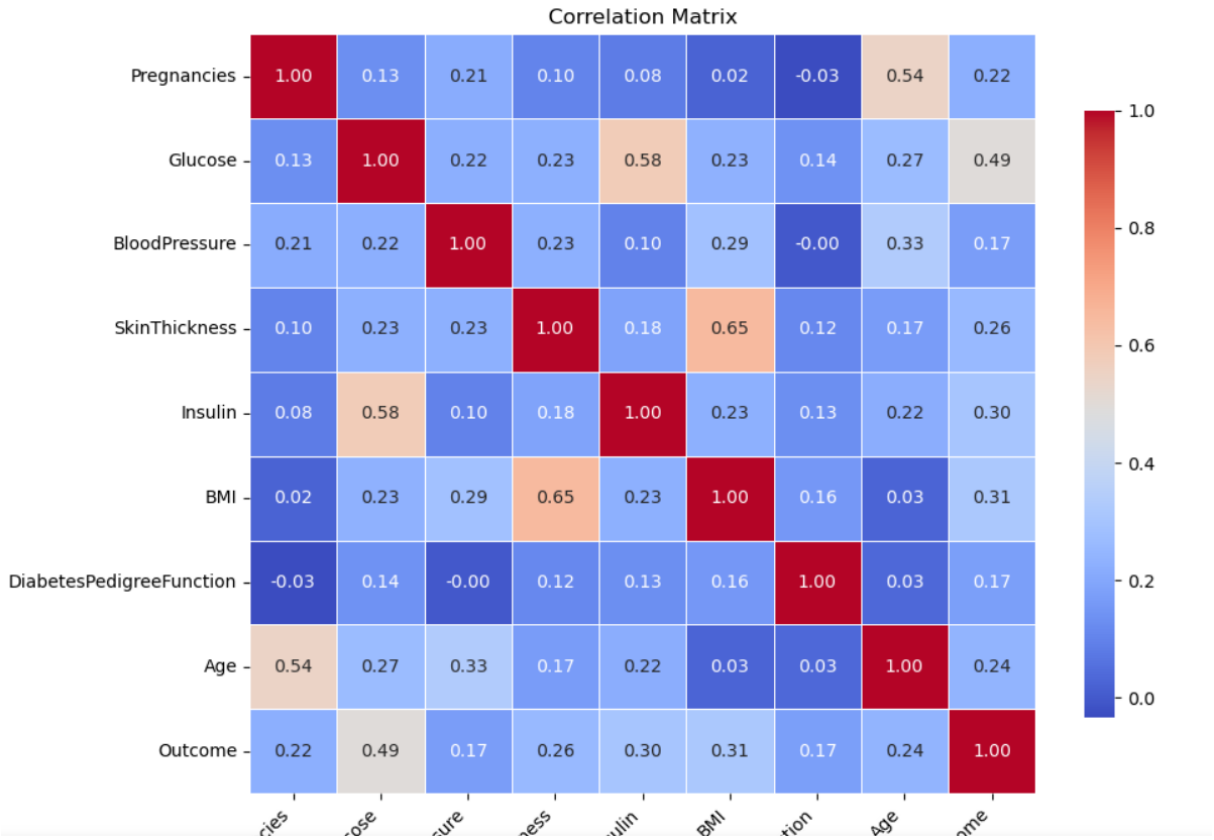

Hình 5. Ma trận tương quan giữa các đặc trưng

Dựa trên kết quả phân tích, **Glucose** và **BMI** thể hiện sự tương quan đáng kể nhất đối với kết quả dự đoán (Outcome). Đặc biệt, mối tương quan giữa các cặp biến như **SkinThickness - BMI và Insulin - Glucose** gợi ý về khả năng tồn tại các mối quan hệ tương tác phức tạp. Đây là căn cứ khoa học để nhóm thực hiện Giai đoạn 4: Feature Engineering, tập trung tạo ra các biến tương tác như BMI_Age và Glucose_BMI nhằm tối ưu hóa sức mạnh dự báo của mô hình.

Phân tích đặc trưng nâng cao

- **Xử lý giá trị ngoại lai (Outliers)**: Đánh giá tầm ảnh hưởng của các điểm dữ liệu bất thường. Các kỹ thuật như Clipping (cắt tỉa) hoặc Log transform (biến đổi logarit) — đặc biệt đối với thuộc tính có độ lệch cao như Insulin — sẽ được cân nhắc để giảm nhiễu cho mô hình.

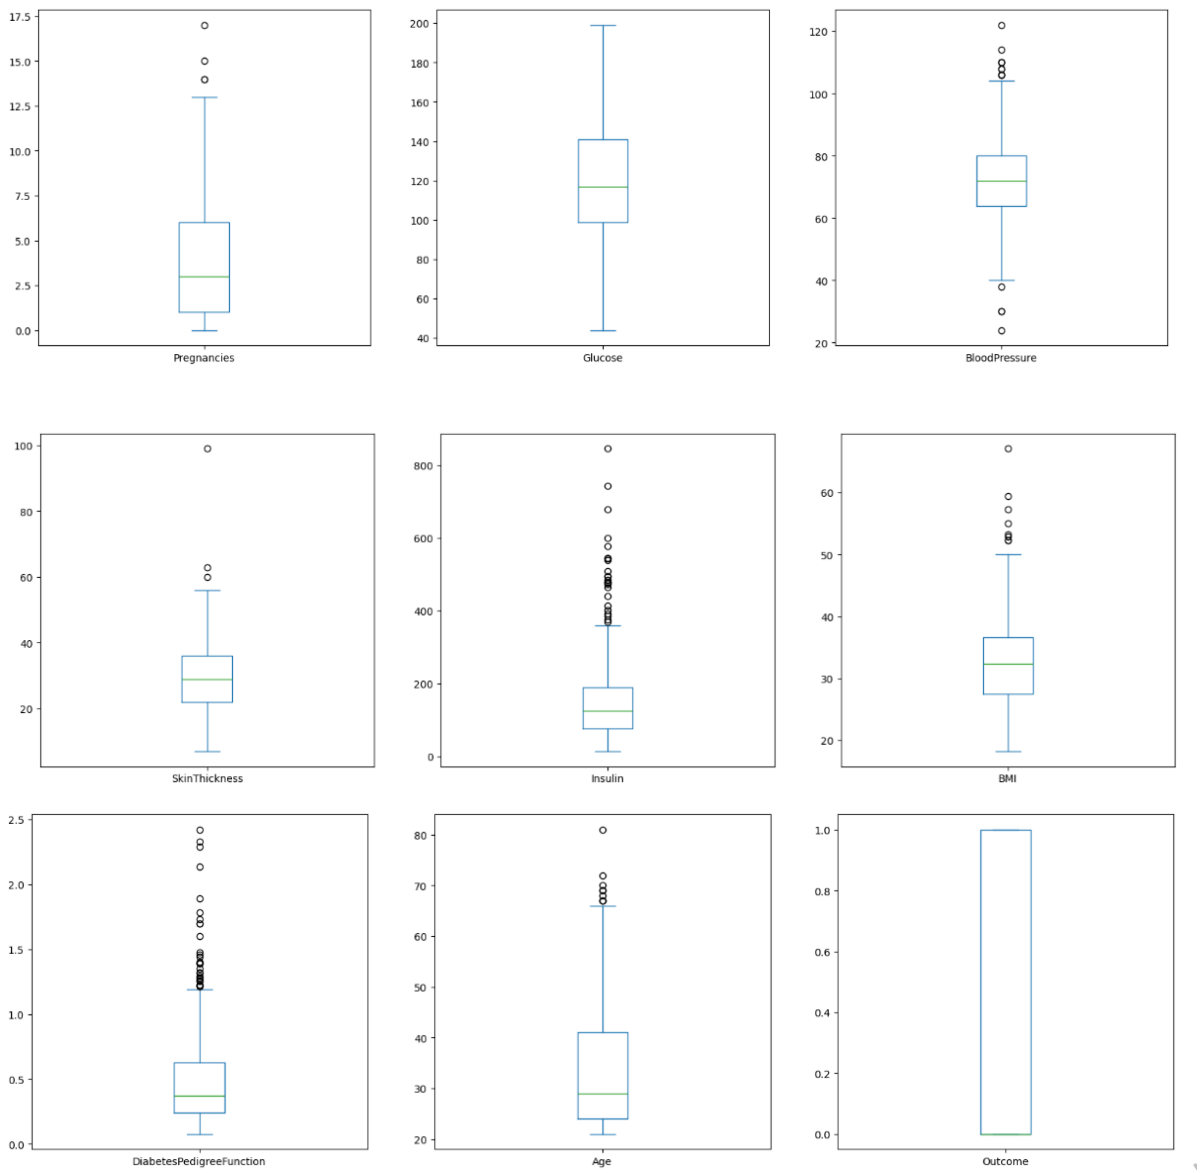

Hình 6. Biểu đồ hợp phân tích các giá trị ngoại lai

Qua quan sát, các biến số sinh học đều chứa lượng lớn giá trị ngoại lai, đặc biệt là Insulin với độ lệch rất lớn. Kết quả này trực tiếp dẫn đến việc triển khai Giai đoạn 3: Xử lý Outlier, nơi các kỹ thuật như Clipping và Log transform được áp dụng để giảm thiểu ảnh hưởng của các điểm dữ liệu bất thường này, từ đó nâng cao độ chính xác và tính ổn định của mô hình dự đoán

- **Đánh giá tương quan**: Khám phá mối quan hệ giữa các biến số để định hướng cho việc tạo ra các đặc trưng mới (Feature Engineering) ở các giai đoạn sau, ví dụ như sự kết hợp giữa BMI và độ tuổi.

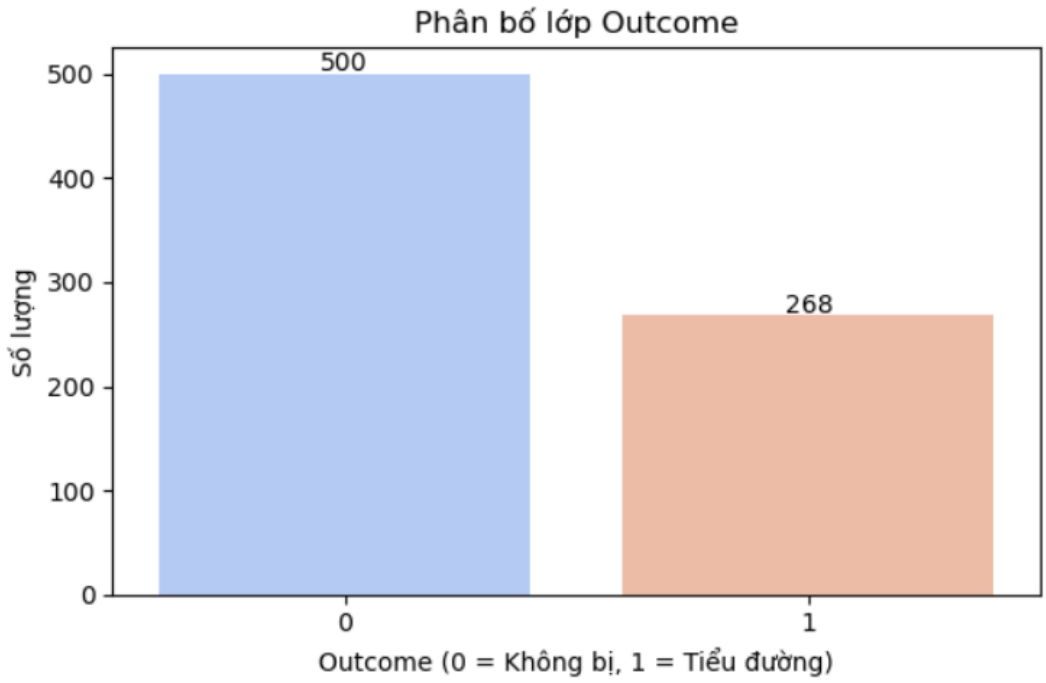

Hình 7. Biểu đồ phân bố số lượng mẫu giữa nhóm không bị tiểu đường và nhóm bị tiểu đường

- **Nhận diện sự mất cân bằng dữ liệu (Class Imbalance):** Biểu đồ cho thấy số lượng mẫu "Không bị tiểu đường" (0) nhiều gần gấp đôi số mẫu "Bị tiểu đường" (1). Điều này báo hiệu rằng mô hình có xu hướng dễ dự đoán nhầm các ca bệnh thành không bệnh.
- **Cơ sở chọn chỉ số đánh giá:** Do sự chênh lệch này, việc chỉ sử dụng độ chính xác (Accuracy) trong các notebook từ **v1** đến **v6** là chưa đủ. Ta có thể bổ sung lập luận rằng cần quan tâm đến các chỉ số như **F1-score** hoặc **Recall** để đảm bảo không bỏ sót các trường hợp thực sự mắc bệnh.
- **Định hướng cho Giai đoạn 5 & 6:** Sự mất cân bằng này giải thích tại sao cần so sánh nhiều mô hình (như Random Forest, SVM) và tinh chỉnh tham số (Tuning). Các mô hình mạnh như Random Forest thường xử lý dữ liệu mất cân bằng tốt hơn Logistic Regression cơ bản.

2.2. Tiền xử lý dữ liệu

Nạp và kiểm tra tính hợp lệ

- **Nạp dữ liệu: Kết nối và đọc dữ liệu thô từ các tệp định dạng .csv** hoặc **.xlsx** vào cấu trúc DataFrame để xử lý.
- **Rà soát giá trị lỗi:** Tập trung kiểm tra các giá trị bằng 0 trong các cột chỉ số sinh học quan trọng như Glucose, BMI, và Huyết áp. Trong y học, các chỉ số này bằng 0 thường là lỗi dữ liệu thay vì giá trị thực.

- **Xử lý giá trị thiếu:** Thay thế các giá trị 0 không hợp lệ bằng **NaN** (giá trị trống) , sau đó thực hiện điền thiếu bằng phương pháp **Median** (trung vị) để giảm thiểu sự sai lệch phân phối.

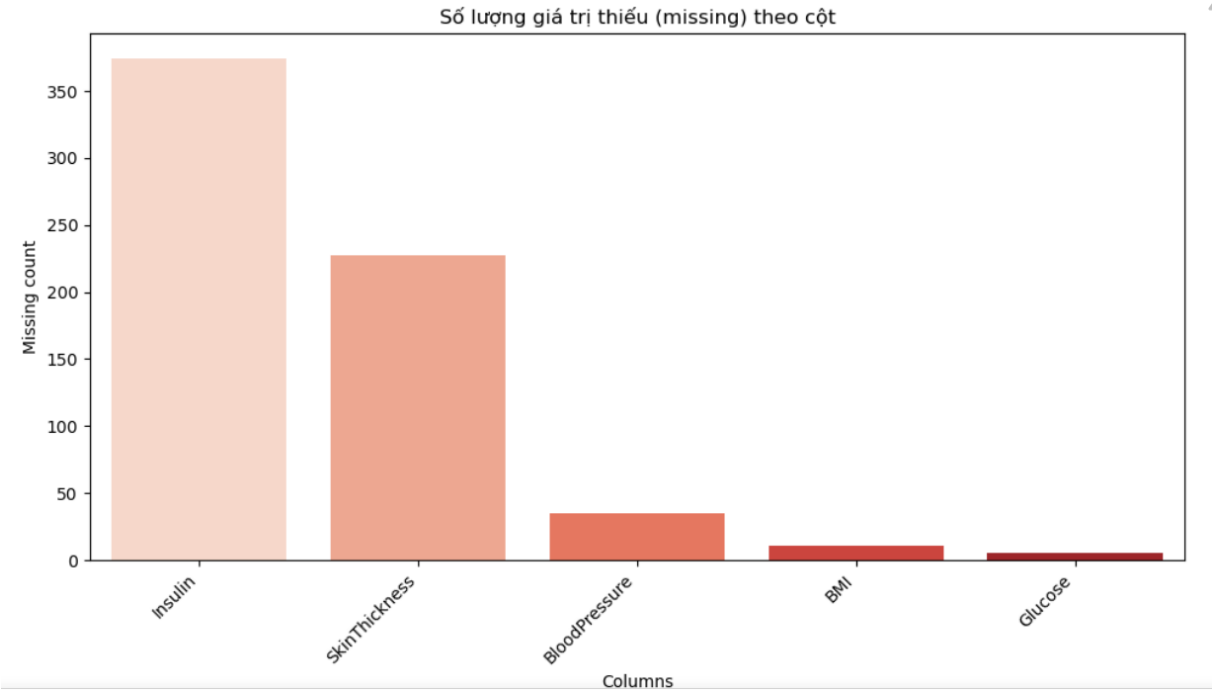

Hình 8. Biểu đồ thống kê số lượng giá trị thiếu trên từng đặc trưng

Cột **Insulin** có lượng giá trị thiếu (giá trị 0) cao nhất, vượt mức 350 bản ghi. Điều này giải thích tại sao ở **Giai đoạn 3**, chúng ta cần các phương pháp xử lý đặc biệt như **Log transform** cho riêng thuộc tính này để giảm ảnh hưởng của nhiễu và ngoại lai.

Do số lượng giá trị thiếu ở **Insulin** và **SkinThickness** rất lớn, việc xóa bỏ các dòng này sẽ làm mất gần một nửa dữ liệu huấn luyện. Vì vậy, phương án **điền giá trị thiếu bằng median** (giá trị trung vị) là lựa chọn tối ưu để bảo toàn kích thước mẫu

Các biến như **Glucose** và **BMI** có lượng giá trị thiếu rất ít (dưới 15 bản ghi). Việc rà soát và xử lý chúng giúp đảm bảo tính chuẩn xác cho các đặc trưng quan trọng nhất trong việc dự đoán tiểu đường

Qua biểu đồ, có thể thấy Insulin là đặc trưng có dữ liệu thiếu trầm trọng nhất. Kết quả này là cơ sở để nhóm triển khai bước thay thế giá trị 0 bằng NaN và áp dụng kỹ thuật Impute (điền khuyết)

Phân chia dữ liệu (Data Splitting)

- **Tách tập dữ liệu:** Dữ liệu được chia thành hai phần độc lập: tập **Train** để huấn luyện và tập **Test** để đánh giá.

- **Chống rò rỉ thông tin (Data Leakage):** Việc phân chia này phải được thực hiện **trước** khi tính toán Median hoặc Scaling. Điều này đảm bảo các thông số xử lý chỉ được học từ tập Train, tránh việc thông tin từ tập Test gây ảnh hưởng đến tính khách quan của mô hình.

Chuẩn hóa và Biến đổi đặc trưng (Scaling & Transformation)

- **Chuẩn hóa (Scaling):** Áp dụng **StandardScaler** để đưa các thuộc tính về cùng một thang đo. Bước này cực kỳ quan trọng đối với các mô hình nhạy cảm với khoảng cách như SVM hay KNN.
- **Xử lý ngoại lai (Outliers):** Sử dụng kỹ thuật **Clipping** để giới hạn biên độ dữ liệu hoặc áp dụng **Log transform** (biến đổi logarit) cho các cột có độ lệch cao như Insulin nhằm giảm nhiễu.

Kỹ nghệ đặc trưng (Feature Engineering)

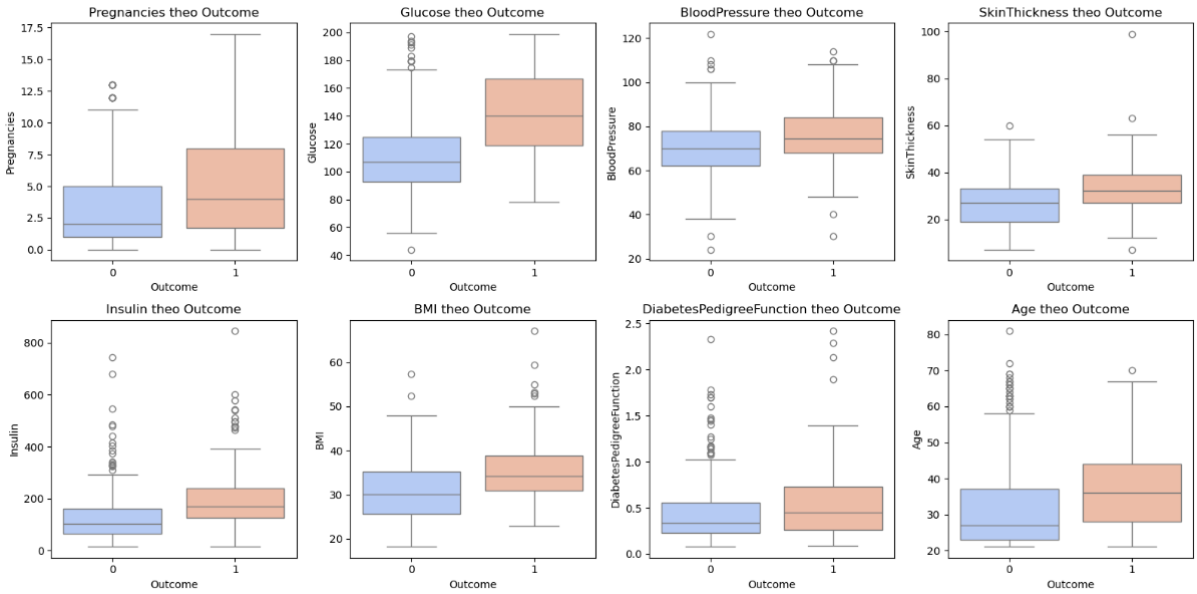

Hình 9. Biểu đồ phân tích đặc trưng để xác định các biến có khả năng phân loại cao

- **Glucose theo Outcome:** Biểu đồ cho thấy sự khác biệt rõ rệt nhất; nhóm bị tiểu đường (1) có dải Glucose cao hơn hẳn nhóm không bị (0). Điều này minh chứng Glucose là đặc trưng quan trọng nhất, hỗ trợ cho việc tạo biến tương tác **Glucose_BMI** ở Giai đoạn 4.
- **BMI và Age theo Outcome:** Cả hai đặc trưng này đều có xu hướng cao hơn ở nhóm bệnh nhân dương tính. Việc quan sát thấy sự phân tách này củng cố cho hướng giải quyết tạo đặc trưng mới **BMI_Age** để tăng khả năng biểu diễn của dữ liệu.
- **Tương quan đồng nhất:** Hầu hết các chỉ số (Pregnancies, Insulin, SkinThickness) đều có trung vị (vạch ngang giữa hộp) của nhóm bệnh lý cao hơn nhóm bình thường. Điều này khẳng định tập dữ liệu có tính phân

loại tốt, là cơ sở để kỳ vọng hiệu năng cao từ các mô hình như **Random Forest** hay **SVM** ở Giai đoạn 5.

- Nhằm tăng khả năng biểu diễn của dữ liệu, các đặc trưng mới sẽ được tạo ra thông qua việc kết hợp các biến có sẵn:
    - **BMI_Age:** Tích số giữa chỉ số BMI và Tuổi (BMI \BMI_Age).
    - **Glucose_BMI:** Tích số giữa nồng độ Glucose và chỉ số BMI (Glucose_BMI)

2.3. Huấn luyện mô hình

Quá trình huấn luyện mô hình được thực hiện theo chiến lược thử nghiệm từng bước, từ các mô hình cơ bản đến các kỹ thuật tối ưu hóa phức tạp để đạt được hiệu quả dự báo cao nhất.

Xây dựng mô hình cơ sở (Baseline Model)

- **Mục tiêu**: Tạo ra một cột mốc so sánh ban đầu cho các thử nghiệm sau này.
- **Thuật toán**: Sử dụng **Logistic Regression**.
- **Đặc điểm**: Trong giai đoạn này, mô hình được huấn luyện trên dữ liệu đã điền thiếu (Median) nhưng **không** áp dụng Scaling hay tinh chỉnh tham số

Thử nghiệm đa mô hình và Scaling

- **Đánh giá ảnh hưởng của Scaling**: Áp dụng **StandardScaler** để kiểm tra mức độ cải thiện hiệu năng trên các dòng thuật toán khác nhau.
- **Các thuật toán thử nghiệm**:
    - **Logistic Regression**: Mô hình tuyến tính cơ bản.
    - **SVM (Support Vector Machine)**: Hiệu quả trong không gian nhiều chiều.
    - **KNN (K-Nearest Neighbors)**: Mô hình dựa trên khoảng cách, rất nhạy cảm với scaling.
    - **Random Forest**: Mô hình dạng cây (Ensemble learning) giúp xử lý tốt các quan hệ phi tuyến

Tối ưu hóa tham số (Hyperparameter Tuning)

- **Phương pháp**: Sử dụng **RandomizedSearchCV** để tìm kiếm bộ tham số tối ưu một cách hệ thống.
- **Phạm vi tinh chỉnh**:
    - **Random Forest**: Tập trung vào số lượng cây (**n_estimators**) và độ sâu tối đa của cây (**max_depth**).

    - **SVM**: Tối ưu hóa tham số phạt **C** và các loại **kernel** (hàm nhân) khác nhau.
- **Kết quả mong đợi**: Tìm ra bộ tham số giúp cải thiện đáng kể độ chính xác và khả năng tổng quát hóa của mô hình

Huấn luyện mô hình cuối cùng (Final Model)

- **Lựa chọn tối ưu**: Tổng hợp phương pháp tiền xử lý tốt nhất và thuật toán có hiệu năng cao nhất từ các bước trên.
- **Huấn luyện lại**: Thực hiện huấn luyện mô hình trên toàn bộ tập dữ liệu Train để tận dụng tối đa lượng thông tin có sẵn.
- **Đóng gói**: Lưu trữ mô hình (**.pkl** hoặc định dạng tương đương) để sẵn sàng triển khai thực tế

2.4. Đánh giá mô hình

Xác định mốc tham chiếu (Baseline): Sử dụng kết quả từ mô hình Logistic Regression cơ bản (v1) để làm tiêu chuẩn đánh giá cho tất cả các cải tiến về sau.
Đánh giá ảnh hưởng của Tiền xử lý: So sánh hiệu năng trước và sau khi áp dụng Scaling (v2) để xác định các mô hình nào (như KNN, SVM) có sự phụ thuộc lớn vào việc chuẩn hóa dữ liệu.
Đo lường mức độ cải thiện: Thực hiện đối chiếu các chỉ số sau khi xử lý Outlier (v3) và thêm đặc trưng mới (v4) để xác định liệu việc làm sạch và biến đổi dữ liệu có thực sự mang lại giá trị gia tăng.
So sánh Đa mô hình và Ghi chép (Logging)

- **Huấn luyện đồng thời**: Thực hiện đánh giá chéo giữa các thuật toán khác nhau bao gồm Logistic Regression, Random Forest, SVM và KNN trên cùng một tập dữ liệu đã chuẩn hóa.
- **Bảng lưu trữ kết quả (Log Table)**: Mọi thông số đo lường đều được ghi lại vào bảng log hệ thống để phục vụ việc phân tích trực quan và chọn ra mô hình có hiệu năng tốt nhất.

Tối ưu hóa và Kiểm định cuối cùng

- **Đánh giá bộ tham số**:Sử dụng kết quả từ **RandomizedSearchCV** để xác định bộ tham số tối ưu (Hyperparameters), đảm bảo mô hình đạt được sự cân bằng giữa độ chính xác và khả năng tổng quát hóa.
- **Kiểm định khách quan (Test Set)**: Mô hình cuối cùng sẽ được đánh giá trên tập Test (tập dữ liệu chưa từng xuất hiện trong quá trình xử lý Median hay Scaling) để đảm bảo kết quả thu được là thực tế và không bị hiện tượng rò rỉ thông tin.

- **Đóng gói mô hình**: Sau khi đạt được các chỉ số mong đợi, mô hình hoàn chỉnh sẽ được lưu lại để sẵn sàng cho việc triển khai thực tế

2.5. Thử nghiệm bổ sung

Kỹ nghệ đặc trưng nâng cao (Advanced Feature Engineering)

- **Mục tiêu**: Tăng khả năng biểu diễn và khai thác các mối quan hệ phi tuyến tính giữa các biến số.
- **Tạo đặc trưng mới**: Thử nghiệm kết hợp các chỉ số sinh học để tạo ra các biến có ý nghĩa lâm sàng cao hơn, ví dụ:
    - **BMI_Age**: Tích số giữa chỉ số khối cơ thể và độ tuổi.
    - **Glucose_BMI**: Tích số giữa nồng độ Glucose và chỉ số BMI.
- **Đánh giá hiệu quả**: Thực hiện kiểm tra xem việc thêm các đặc trưng này có thực sự giúp mô hình học tốt hơn hay không so với việc chỉ sử dụng dữ liệu thô

Tối ưu hóa siêu tham số (Hyperparameter Tuning)

Phương pháp hệ thống: Sử dụng **RandomizedSearchCV** để dò tìm bộ tham số tối ưu thay vì lựa chọn thủ công.

Tinh chỉnh các mô hình trọng điểm:

- **Random Forest**: Tập trung tối ưu hóa số lượng cây huấn luyện (**n_estimators**) và độ sâu tối đa của cây **(max_depth**) để tránh hiện tượng quá khớp (**overfitting**).
- **SVM**: Thử nghiệm với các giá trị tham số phạt **C** và các loại **kernel** khác nhau để tìm ra ranh giới phân loại tốt nhất.

Kết quả mong đợi: Tìm được bộ tham số giúp cải thiện đáng kể hiệu năng dự đoán và khả năng tổng quát hóa trên dữ liệu mới.

Xây dựng và Lưu trữ mô hình cuối cùng (Final Model)

Tổng hợp tối ưu: Lựa chọn phương pháp tiền xử lý hiệu quả nhất và mô hình có kết quả cao nhất từ các bước thử nghiệm trước đó.
Huấn luyện toàn diện: Thực hiện huấn luyện lại mô hình trên toàn bộ tập dữ liệu Train để đảm bảo mô hình học được tối đa thông tin.
Đóng gói sản phẩm: Lưu mô hình hoàn chỉnh dưới dạng file để sẵn sàng tích hợp vào các ứng dụng hoặc hệ thống thực tế

CHƯƠNG 3: KẾT QUẢ VÀ ĐÁNH GIÁ

3.1 Kết quả thực nghiệm

Sau khi thực hiện thử nghiệm, mô hình cuối cùng được lựa chọn là Random Forest Classifier với bộ tham số tối ưu từ bước Tuning.
Bảng so sánh hiệu năng:

STT	Mô hình	Accuracy	F1-score
1	**RandomForestClassifier**	**0.7706**	**0.6748**
2	SVC	0.7489	0.6234
3	LogisticRegression	0.7359	0.6065
4	KNeighborsClassifier	0.7229	0.6000

Nhận xét:

- **Random Forest Classifier** đạt kết quả cao nhất về độ chính xác (Accuracy) là 77.06% và F1-score là 0,6748.
- **Kết quả:** Cho thấy sự tăng trưởng rõ rệt so với mô hình Baseline (Logistic Regression) ban đầu, qua đó chứng minh được rằng việc thực hiện tiền xử lý dữ liệu và tối ưu hóa tham số đã đi đúng hướng

3.2 Phân tích và đánh giá

3.2.1 Phân tích ma trận nhầm lẫn

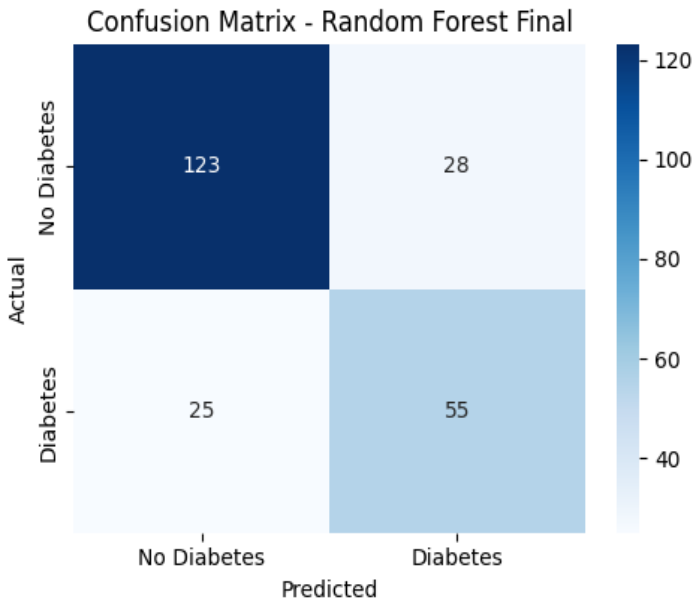

Hình 10. Ma trận nhầm lẫn đánh giá hiệu suất của mô hình Random Forest

Ma trận nhầm lẫn của mô hình Random Forest trên tập dữ liệu kiểm tra (231 mẫu) cho kết quả như sau:

- **True Negative (TN) = 123:** Có 123 trường hợp người thực tế không bị tiểu đường và mô hình đã dự đoán chính xác là không bị bệnh.
- **True Positive (TP) = 55:** Có 55 trường hợp người thực tế bị tiểu đường và mô hình đã dự đoán chính xác là có bệnh.
- **False Positive (FP) = 25:** Có 25 trường hợp người thực tế không bị bệnh nhưng mô hình dự đoán thành có bệnh.
- **False Negative (FN) = 28:** Có 28 trường hợp người thực tế bị tiểu đường nhưng mô hình dự đoán là không có bệnh.

Nhận xét:

- **Độ chính xác tổng thể:** Mô hình có độ chính xác 77.06% (178 trong 231 mẫu)
- **Hiệu quả phân loại nhóm không bệnh:** Mô hình thể hiện khả năng nhận diện rất tốt những người không bị tiểu đường (123/148 mẫu)
- **Hiệu quả phân loại nhóm có bệnh:** Mô hình vẫn còn bỏ sót một lượng bệnh nhân mắc bệnh tiểu đường

3.2.2 Đánh giá Tầm quan trọng của đặc trưng

Phân tích chi tiết: Dựa trên kết quả từ mô hình Random Forest, mức độ đóng góp của các đặc trưng vào việc đưa ra quyết định dự báo được xếp hạng như sau:

- **Glucose:** Đây là đặc trưng có tầm quan trọng cao nhất so với các biến còn lại. Kết quả này hoàn toàn đúng với thực tế, vì Glucose là chỉ số tiên quyết để xác định tình trạng bệnh lý tiểu đường.
- **BMI và Age (Chỉ số khối cơ thể & Độ tuổi):** Hai đặc trưng này đứng ở vị trí tiếp theo. Điều này phản ánh mối liên quan chặt chẽ giữa thể trạng (thừa cân, béo phì) và yếu tố lão hóa đối với nguy cơ kháng Insulin.
- **Glucose_BMI:** Đặc trưng tương tác mới được nhóm tạo ra nằm trong nhóm có trọng số quan trọng. Việc kết hợp giữa đường huyết và chỉ số BMI giúp mô hình khai thác được những mối quan hệ phi tuyến tính mà các biến đơn lẻ không thể hiện rõ.
- **Các chỉ số khác:** Các biến như Huyết áp (BloodPressure) có tầm quan trọng thấp hơn, cho thấy chúng đóng vai trò là các yếu tố bổ trợ thay vì là yếu tố quyết định trực tiếp trong bộ dữ liệu này.

CHƯƠNG 4: HƯỚNG CẢI TIẾN MÔ HÌNH

4.1 Xử lý mất cân bằng dữ liệu

Hiện tại số lượng mẫu "không bị bệnh" đang nhiều hơn "có bệnh". Nhóm sẽ áp dụng kỹ thuật **SMOTE** để cân bằng lại tập dữ liệu huấn luyện, giúp mô hình nhận diện lớp 1 (có bệnh) tốt hơn và giảm tỷ lệ bỏ sót ca bệnh (FN)

4.2 Thử nghiệm các mô hình Boosting

Ngoài Random Forest, các thuật toán như XGBoost hoặc LightGBM sẽ được đưa vào thử nghiệm. Đây là những mô hình mạnh trong việc xử lý dữ liệu bảng (tabular data), có khả năng giảm thiểu sai số tốt hơn thông qua cơ chế học bù trừ.

4.3 Kỹ thuật đặc trưng chuyên sâu

Tiếp tục nghiên cứu để tạo ra các biến tương tác mới dựa trên kiến thức y khoa. Bên cạnh đó, việc thực hiện chọn lọc đặc trưng (Feature Selection) khắt khe hơn sẽ giúp loại bỏ các biến gây nhiễu, làm mô hình gọn nhẹ và chính xác hơn.

4.4 Mở rộng kích thước mẫu

Bộ dữ liệu hiện tại (768 mẫu) là khá nhỏ đối với các bài toàn học máy. Việc thu thập thêm dữ liệu từ các nguồn khác sẽ giúp mô hình có khả năng tổng quát tốt hơn, tránh hiện tượng quá khớp (Overfitting) trên tập dữ liệu nhỏ.

TÀI LIỆU THAM KHẢO

[1] Scikit-learn Documentation: *Random Forest Classifier & Hyperparameter Tuning*.
[2] Kaggle: *Pima Indians Diabetes Database*.
[3] Giáo trình Cơ sở Trí tuệ nhân tạo: *Khoa CNTT - Trường Đại học Sài Gòn*.
[4] Aurélien Géron (2019): *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*.

THANK YOU FOR LISTENING